تقرير مشروع Titanic

شرح خطوات التنظيف والتحليل والرسومات | 19 أكتوبر 2026

هدف المشروع

تحليل بيانات ركاب Titanic لفهم جودة البيانات، معالجة القيم الناقصة، ومقارنة أنماط النجاة حسب الجنس ودرجة التذكرة والعمر والأسرة. التقرير يوثق ما تنفذ فعلا في النسخة الجديدة ويفصل بين التعديلات والنسخة الأصلية.

النتيجة الأساسية

تضم العينة 891 راكبا و12 عمودا أصليا. نجا 342 راكبا بنسبة 38.38%، ولم ينج 549. لم نحذف ركابا خلال التنظيف.

الملفات المسلمة

Titanic_cleaning.ipynb: النسخة الأصلية محفوظة دون تعديل.

Titanic_analysis_updated.ipynb: النسخة الجديدة، وتحتوي الكود كاملا مع علامات MODIFIED وشروح عربي.

figures/original/: الصور السبع المستخرجة من المخرجات الأصلية. figures/: تسع صور جديدة.

output/titanic_cleaned.csv: البيانات الناتجة.

output/analysis_summary.json: ملخص أرقام قابل للمراجعة.

README.md وCHANGELOG.md: دليل التعديلات والتشغيل.

نطاق النتائج

هذا مشروع تحليل وصفي على ملف train.csv المحلي. لا يشمل كل ركاب السفينة، ولا يحتوي نموذج تعلم آلة، أو دقة تنبؤ، أو إثباتا سببيا. مصدر النتائج هو البيانات المحلية والتنفيذ الفعلي للنوتبوك. لم يتم توثيق مصدر تحميل ملف CSV بصورة مستقلة.

1. قراءة البيانات وفهم الأعمدة

Titanic | Data Cleaning & Exploratory Analysis

النسخة الأصلية تقرأ البيانات من مسار Google Drive ثابت. النسخة الجديدة تقرأ train.csv من مجلد العمل، ولذلك يمكن تشغيلها محليا أو على Colab بعد رفع الملف إلى المجلد نفسه. إذا غاب الملف تتوقف برسالة واضحة بدل قراءة ملف آخر بالخطأ.

قاموس البيانات

PassengerId: معرف الراكب، وليس متغيرا يفسر النجاة.

Survived: 0 نجا، 1 لم ينج. Pclass: الأولى أو الثانية أو الثالثة.

Name وSex وAge: الاسم والجنس والعمر بالسنوات. قد يكون العمر كسريا للأطفال.

SibSp: الأشقاء أو الزوج/الزوجة المسجلون على السفينة. Parch: الآباء والأبناء.

Fare: رقم التذكرة وسعرها المسجل. قد يكون السعر مرتبطا بحجز مشترك، وليس دخلا شخصيا وTicket.

Cabin: الكابينة المسجلة؛ غيابها يعني غياب المعلومة.

Embarked: ميناء الصعود؛ C وQ وS ترمز إلى Cherbourg وQueenstown وSouthampton.

فحوص قبل أي تعديل

نتحقق من الأعمدة المطلوبة، وفردية PassengerId، وأن Survived يساوي صفرا أو واحدا، وأن الدرجة ضمن 1 و2 و3. نتحقق من عدم سلبية الأسعار ومن نطاق العمر. نعرض info وdescribe وعدد المفقود والتكرارات. الملف الحالي بلا صفوف مكررة مطابقة.

نسخة خام ومسافات النصوص

df_clean = df.copy(deep=True) يحافظ على البيانات الأصلية. نزيل المسافات الزائدة من أسماء الأعمدة والنصوص، ونحول النص الفارغ إلى قيمة مفقودة قبل التعويض.

ميناء الصعود Embarked

عوضنا 2 قيمتين مفقودتين بالمنوال المحسوب من البيانات، وهو S في الملف الحالي. أضفنا EmbarkedWasMissing لتوثيق أن هذه القيم مقدرة، بدل إخفاء تاريخها.

العمر Age

عوضنا 177 عمرا بوسيط كل مجموعة تجمع Pclass وSex باستخدام groupby ثم transform('median'). لو لم يتوافر وسيط لمجموعة نستخدم وسيط العمر العام كحل احتياطي. أضفنا AgeWasMissing قبل التعويض.

الوسيط أقل تأثرا بالقيم الشديدة من المتوسط. التجميع يحترم بعض اختلافات الأعمار بين الفئات، لكنه لا يعيد العمر الحقيقي لكل راكب. استخدام قيم متكررة للتعويض قد يضيف قمما مصطنعة إلى الرسم، ولذلك أضفنا رسما للأعمار المسجلة فقط للمقارنة.

قرار Cabin

احتفظنا بعمود Cabin وبـ687 قيمة مفقودة فيه. أضفنا HasCabin = Cabin.notna().astype(int). لا نفترض أن المفقود يعني عدم وجود كابينة، ولا نحذف أغلب الركاب بسبب نقص هذا العمود. فحوص النهاية تسمح بهذا المفقود الموثق فقط.

كشف وليس حذف :Fare

حسب Q1 وQ3 ثم IQR = Q3 - Q1. الحد العلوي يساوي Q3 + 1.5 × IQR = 65.6344. توجد 116 قيمة أعلى منه. احتفظنا بها وأضاف الكود FareHighOutlier لتمييزها؛ التذاكر العالية قد تكون حقيقية، ولا نملك دليلا يجعلها أخطاء.

حجم الأسرة والسفر منفردا

إذا كان الحجم واحدا، وإلا صفر. المقصود هو IsAlone = 1. لأن الراكب نفسه يدخل في الحجم، FamilySize = SibSp + Parch + 1 الأقارب المسجلون في هذه الأعمدة؛ لا نستطيع الجزم بأنه بلا أصدقاء أو معارف على السفينة.

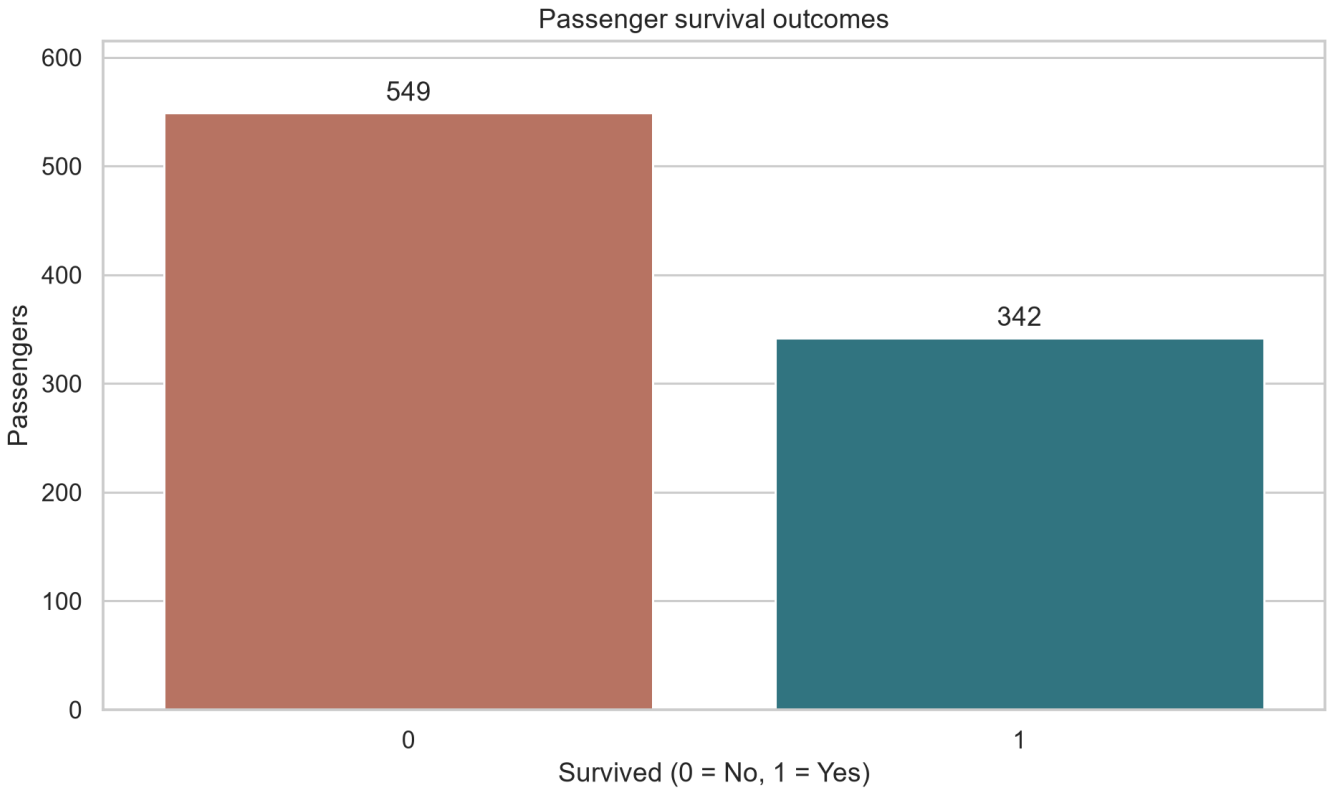
تعريف الطفل وتصحيح التعليق

صححنا التعليق القديم الذي كان يشير إلى أكبر من 16 بينما الكود يستخدم أصغر من 16. العدد بعد IsChild = (Age < 16).astype(int). التعويض 83، والعدد بعمر مسجل فعلا 83. هذا العدد يخص العينة، ولا يمثل العدد التاريخي لكل الأطفال على السفينة.

أثر التعديلات على الرسومات

حافظنا على موضوعات الرسومات الأصلية. أضفنا عناوين ووحدات وحفظا آليا للصور. استبدلنا تكرار رسم العمر بفحص أثر التعويض، وركزنا على المتغيرات المفيدة بدل إدراج المعرفات وكل المتغيرات الثنائية. أضفنا مقارنة نسب النجاة وتحليل اكتمال pairplot Cabin.

4.1 Survival counts

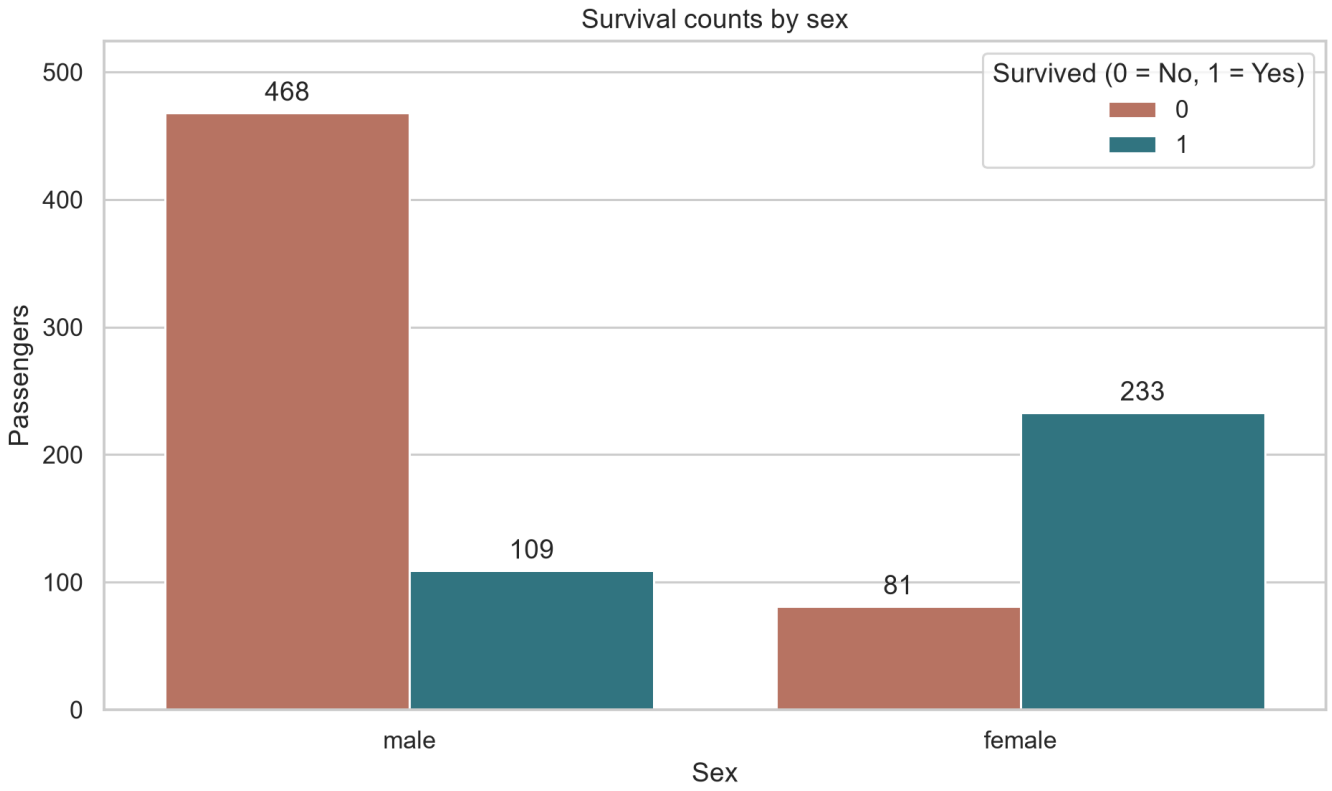


الشرح والاستنتاج

المحور الأفقي يقسم الركاب إلى لم ينج ونجا، والرأسي يمثل عدد الركاب. الأرقام فوق الأعمدة تعطي العدد الفعلي. هذه نقطة البداية لفهم عدم توازن النتيجة؛ لا نفترض أن فرص النجاة كانت متساوية لمجرد وجود فئتين. نسب النجاة هنا تخص ملف التدريب فقط.

الأعداد الفعلية: 342 نجا، و549 لم ينج. نسبة النجاة 38.38%.

ملف الصورة: survival_counts.png_01



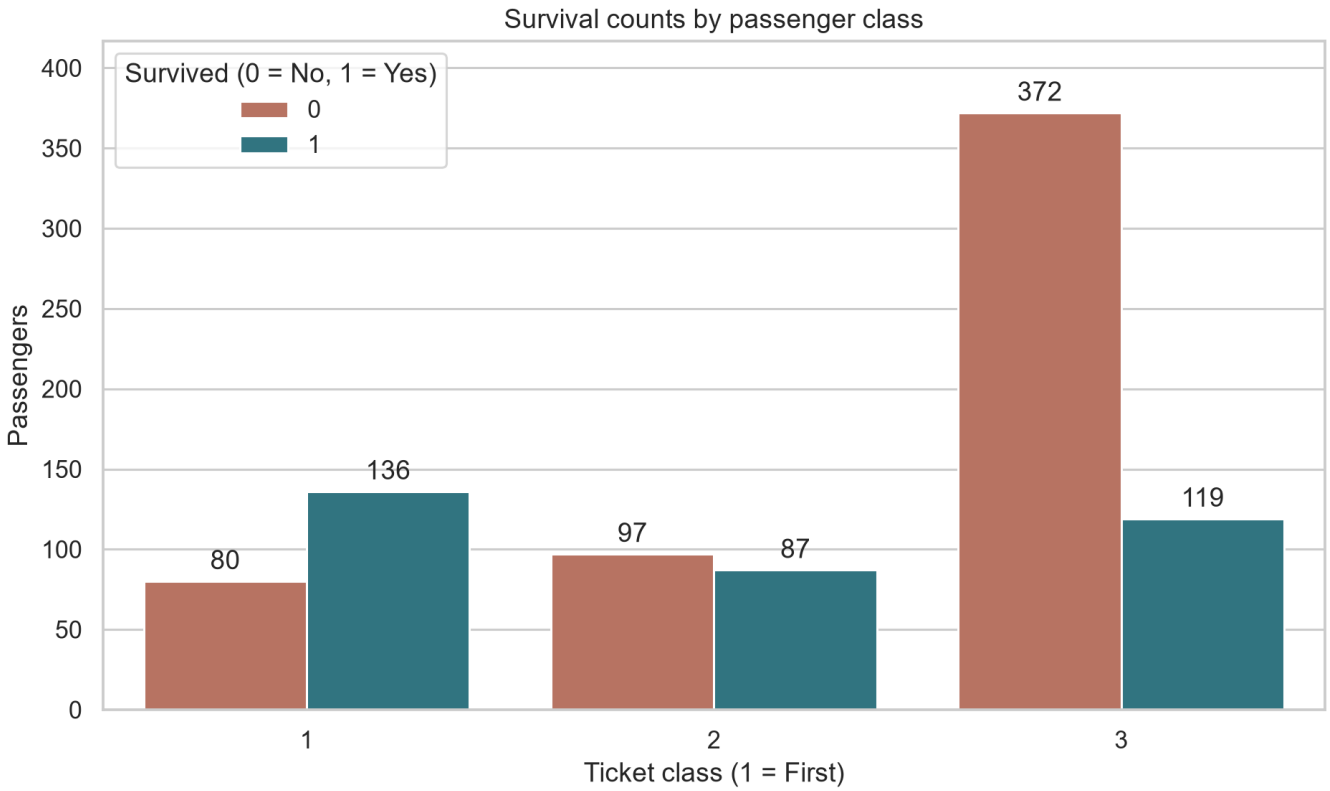
الشرح والاستنتاج

داخل كل فئة للجنس نقارن عمود الناجين بعمود غير الناجين. ارتفاع عدد الركاب الذكور يؤثر في الأعداد المطلقة، لذلك يجب قراءة جدول نسبة النجاة مع الرسم. الفروق المرصودة ارتباطات في العينة وقد تتداخل مع الدرجة والعمر؛ لا يمثل الجنس وحده تفسيرا سببيا.

في العينة: 314 أنثى، نجا منهن 233؛ و577 ذكرا، نجا منهم 109. نجاة الإناث 74.2%، والذكور 18.89%.

ملف الصورة: sex_survival_counts.png_02

4.3 Passenger class and survival counts

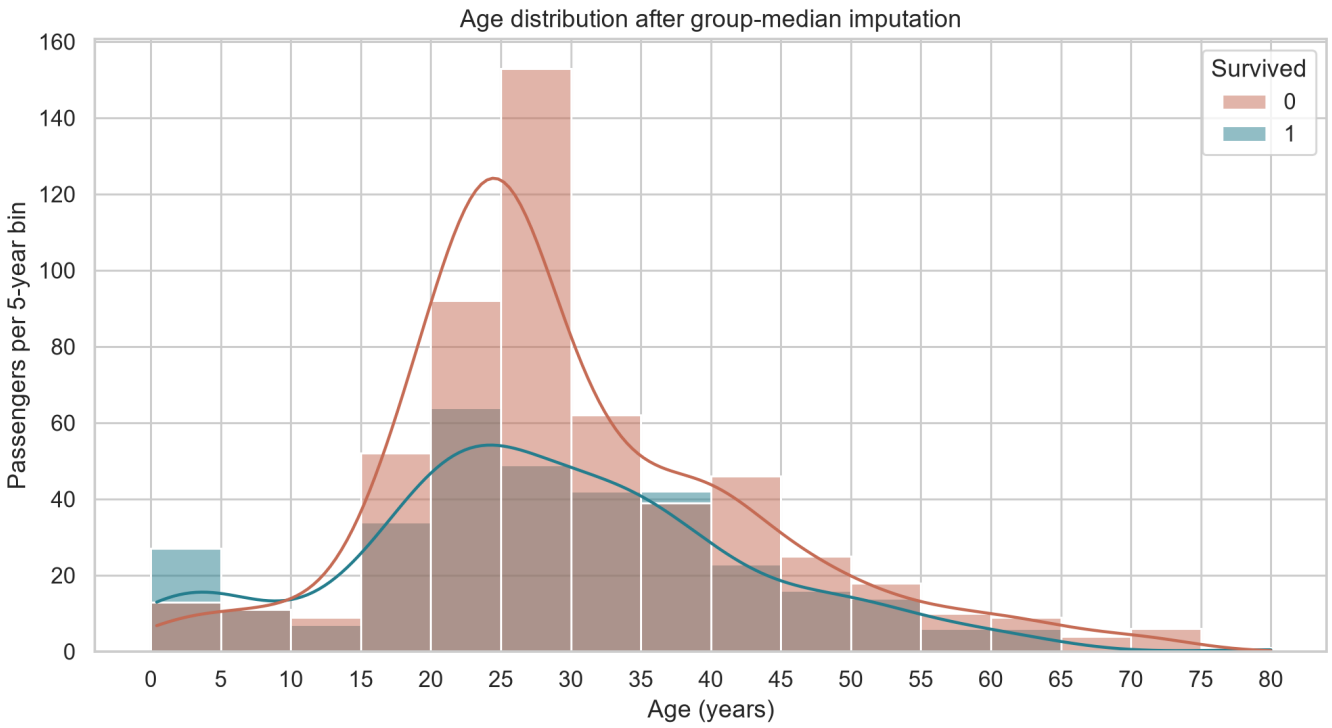


الشرح والاستنتاج

المحور الأفقي يوضح درجات التذاكر من الأولى إلى الثالثة. نقارن الناجين وغير الناجين داخل كل درجة، ثم نستخدم معدلات النجاة للمقارنة بين الدرجات المختلفة في الحجم. ارتفاع عدد الوفيات في الثالثة يحتاج إلى النظر إلى عدد ركابها أيضا. الرسم لا يعزل أثر الجنس أو العمر أو موقع الراكب.

الأولى: 216 راكبا، 136 ناجيا؛ الثانية: 184 راكبا، 87 ناجيا؛ الثالثة: 491 راكبا، 119 ناجيا. نسب النجاة: 62.96%، 47.28%، 24.24% على الترتيب.

ملف الصورة: class_survival_counts.png_03



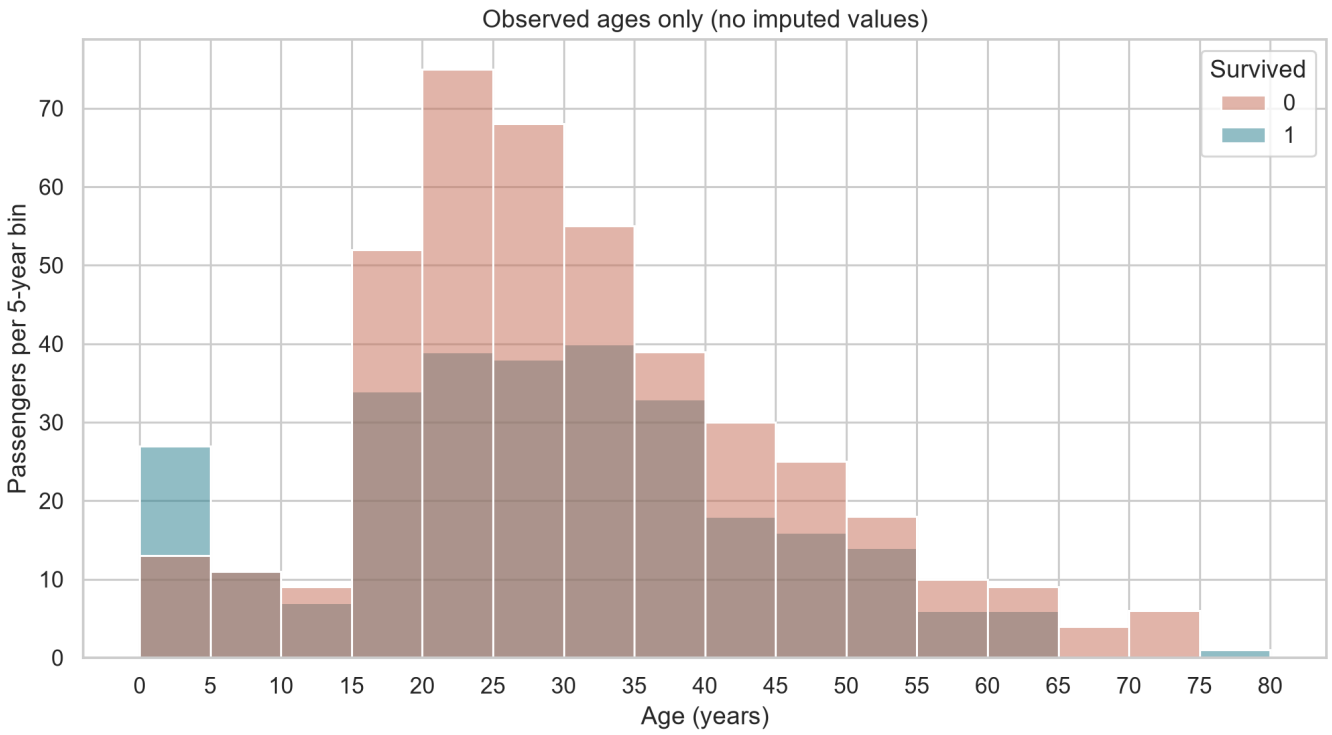
الشرح والاستنتاج

كل عمود يمثل نطاقا عمريا عرضه خمس سنوات، واللون يميز النتيجة. خطوط KDE تلخص شكل التوزيع ولا تمثل احتمالات نجاة مباشرة. القمم قرب بعض الأعمار تتأثر بتعويض الأعمار المفقودة بوسيط المجموعة؛ العدد الأكبر في عمر معين لا يثبت ارتفاع أو انخفاض فرص النجاة فيه.

قراءة الأعمدة تخص أعداد الركاب في كل نطاق؛ لا تقسم بصريا ارتفاع عمودين متداخلين لاستنتاج معدل دقيق. استخدم جدولا بنطاقات العمر إذا أردت مقارنة النسب.

ملف الصورة: age_distribution.png_04

4.5 Age distribution using observed ages only



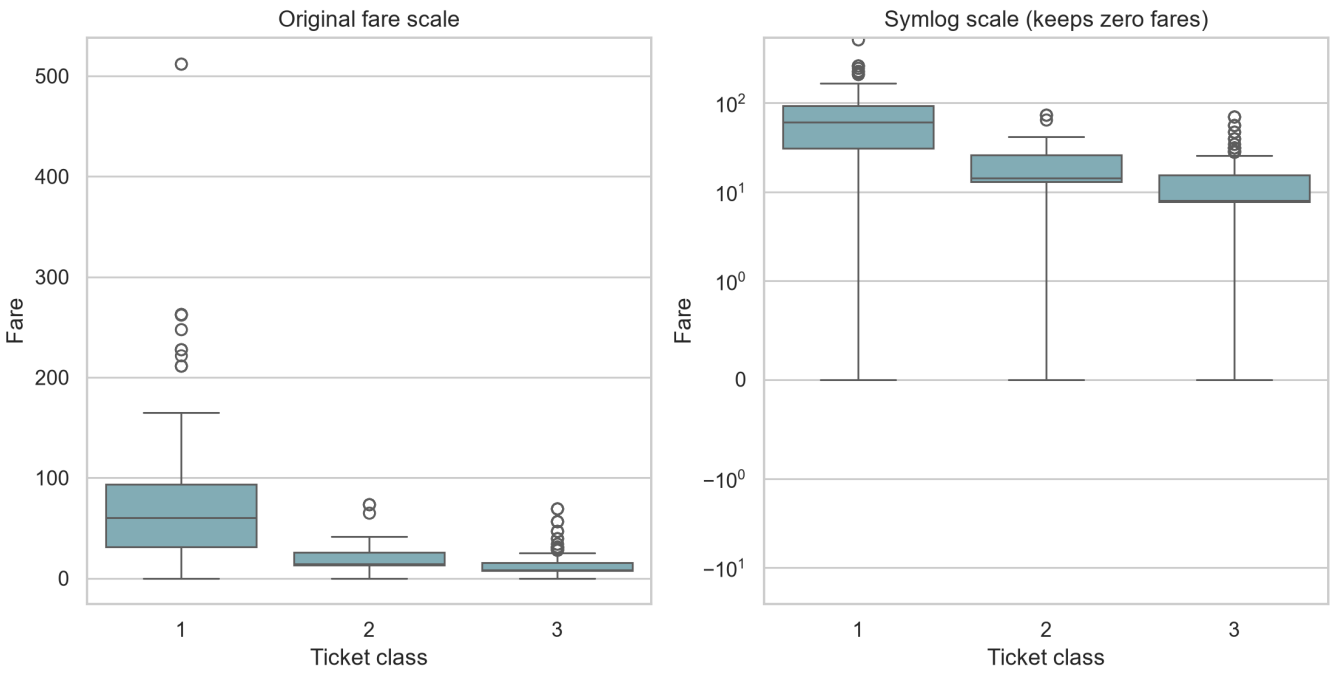
الشرح والاستنتاج

نفس تقسيم الأعمار السابق، لكن الرسم يستبعد الركاب الذين كانت أعمارهم مفقودة. المقارنة مع الرسم السابق توضح مدى تأثر الشكل بالتعويض. هذا فحص حساسية مفيد، لكنه لا يلغي تحيز غياب العمر؛ الركاب ذوو العمر المعروف قد يختلفون عن بقية الركاب.

يستخدم هذا الرسم 714 عمرا معلوما، ويستبعد 177 عمرا مقدرا. اختلافه عن السابق يعرض حساسية الشكل لطريقة التنظيف.

ملف الصورة: age_observed_only.png_05

4.6 Fare distribution by class



الشرح والاستنتاج

الخط داخل الصندوق يمثل الوسيط، وحدا الصندوق الربيعين الأول والثالث. الشوارب تمتد لأبعد قيمة داخل 1.5 IQR، والنقاط خارجها قيم إحصائية متطرفة وليست أخطاء مؤكدة. اللوحة اليسرى تعرض الأسعار الأصلية؛ اليمنى تغير المقياس لتسهيل رؤية القيم الصغيرة مع إبقاء الصفر. لا نخلط المسافات بين اللوحتين ولا نحذف الأسعار العالية تلقائيا.

يستخدم مقياس symlog في اللوحة اليمنى لأنه يتيح عرض الصفر مع ضغط القيم الكبيرة. لا توجد إزالة أو قص للأسعار في البيانات المحفوظة.

ملف الصورة: 06_fare_boxplot.png

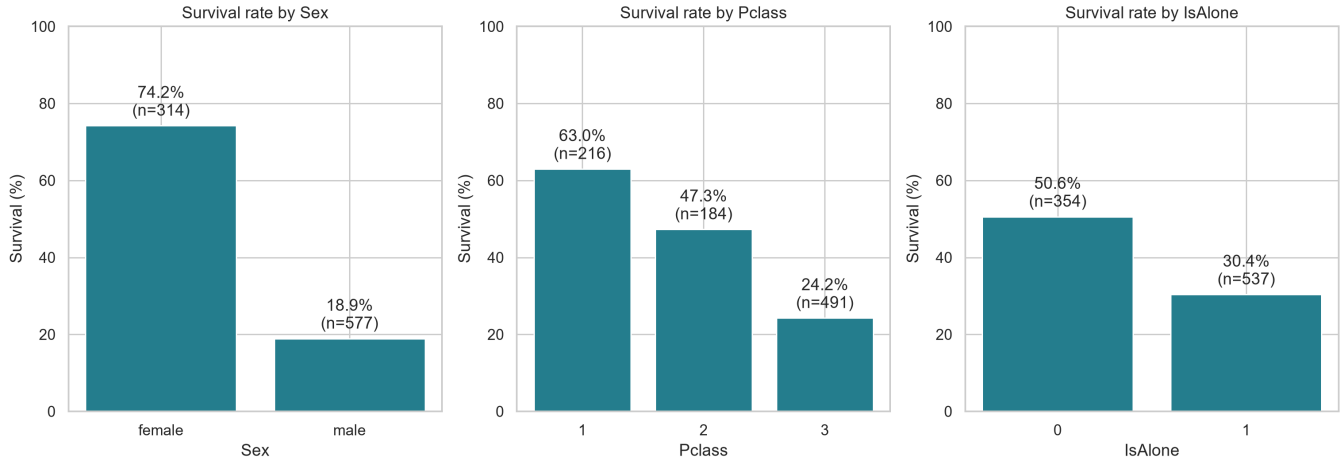


الشرح والاستنتاج

كل لوحة خارج القطر تعرض متغيرين، والقطر يعرض توزيع متغير واحد. اللون يوضح النجاة، وتداخل النقاط يعني أن المتغيرات لا تفصل النتيجة فصلا تاما. استبعدنا PassengerId لأنه معرف، وقللنا المتغيرات الثنائية لتوضيح الرسم. Fare شديد الالتواء وFamilySize متقطع، والعمر يحتوي قيما مقدرة؛ لذلك لا نستنتج علاقة خطية أو سببية من الشكل وحده.

اقرأ اسم الصف باعتباره محور y واسم العمود محور x. القطر يوضح توزيع كل متغير حسب النجاة. تكرار FamilySize في أعداد صحيحة يصنع أشرطة رأسية وأفقية طبيعية.

ملف الصورة: pairplot.png_07



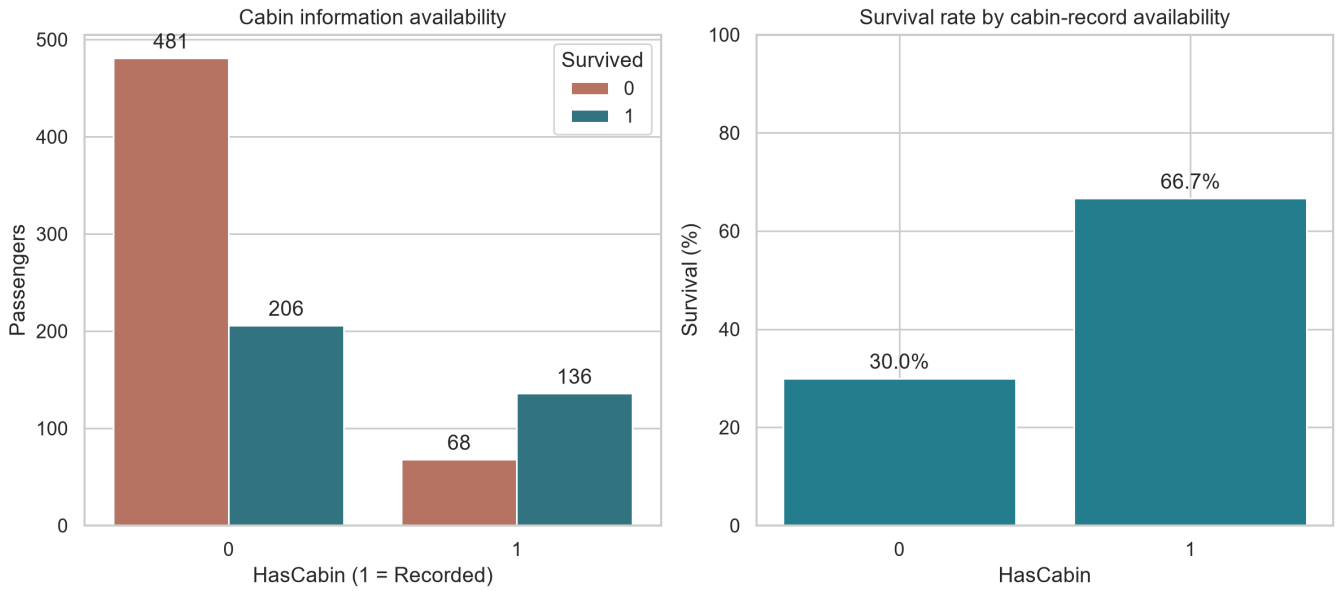
الشرح والاستنتاج

المحور الرأسي هنا نسبة الناجين داخل المجموعة، وليس العدد الكلي. n فوق كل عمود هو حجم المجموعة، وهذا يجعل المقارنة أوضح من مقارنة الأعداد وحدها. IsAlone = 1 يعني السفر دون أقارب مسجلين في SibSp وParch. اختلاف المعدلات لا يثبت أن السفر مع الأسرة سبب النجاة، ولا توجد فترات ثقة أو اختبارات دلالة في هذا الرسم.

نسبة نجاة من يسافرون منفردين 30.35%، ومن معهم أقارب مسجلون 50.56%. هذه مقارنة وصفية غير مضبوطة حسب الدرجة والجنس.

ملف الصورة: survival_rates.png_08

4.9 Cabin information and survival



الشرح والاستنتاج

اللوحة الأولى تعرض أعداد الناجين وغير الناجين حسب توافر رقم الكابينة، والثانية النسبة داخل كل مجموعة. HasCabin يقيس اكتمال التسجيل وليس امتلاك كابينة. جدول التوزيع حسب الدرجة يساعد على كشف تداخل توافر المعلومة مع الدرجة؛ لذلك لا ننسب الفرق لوجود رقم الكابينة كعامل سببي مستقل.

عدد من لديهم Cabin مسجلة 204، وعدد من يغيب رقمها 687. هذا الفرق الكبير في اكتمال المعلومة يمنع التعامل مع العمود كقياس كامل ومتوازن للجميع.

ملف الصورة: cabin_information.png_09

ما الذي تخبرنا به البيانات؟

نسبة النجاة العامة 38.38%. توجد فروق وصفية كبيرة حسب الجنس والدرجة، كما تختلف النسب حسب وجود أقارب مسجلين. يشرح الرسم الثامن لماذا نحتاج إلى المعدلات بجانب الأعداد عند مقارنة مجموعات مختلفة الحجم.

ما الذي لا تثبته البيانات؟

لا تثبت هذه المقارنات أن عاملا واحدا تسبب في النجاة. الجنس والدرجة والعمر وموقع الراكب وإجراءات الإخلاء قد تتداخل. لا توجد اختبارات دلالة أو نماذج مضبوطة أو فترات ثقة هنا، ولا نقدم توقعا لراكب جديد.

محدودية البيانات والتنظيف

الملف عينة تدريب محلية، وليس سجلا كاملا للسفينة. 177 عمرا مقدرا قد تؤثر في توزيع العمر وتصنيف الطفل. Cabin مفقودة بكثرة، وتوافرها قد يعكس جودة التسجيل والدرجة. أسعار التذاكر قد تعكس حجوزات مشتركة. لا توجد مراجعة مستقلة لمصدر تحميل CSV أو ترخيص إعادة توزيعها.

لو تحول إلى مشروع تعلم آلة

نقسم البيانات أولا، ثم نتعلم وسطاء التعويض والمنوال من التدريب وحده. نستخدم Pipeline ونقيم الأداء على بيانات لم تدخل في التعلم. تعويض الملف كاملا هنا مناسب للاستكشاف الوصفي، وليس وصفة لتقييم نموذج دون تسرب بيانات.

6. التحقق وإعادة التشغيل

نفذت خلايا النوتبوك الجديدة بالترتيب. الفحوص النهائية تتحقق من ثبات عدد الصفوف وفردية المعرف وعدم تغيير Survived، ومن اكتمال الأعمدة فيما عدا Cabin، ومن تطابق HasCabin مع غياب المعلومة، ومن وجود الصور التسع. ملف summary يعرض الأرقام الناتجة ويمكن مقارنتها بالتقرير.

خطوات التشغيل على الجهاز

1. ضع train.csv والنسخة الجديدة في المجلد نفسه.
2. ثبت المكتبات المذكورة في requirements.txt في بيئة Python مناسبة.
3. افتح Titanic_analysis_updated.ipynb واختر Python kernel.
4. أعد تشغيل البيئة ونفذ Run All.
5. راجع رسالة Validation passed والملفات في figures وoutput.

خطوات التشغيل على Colab

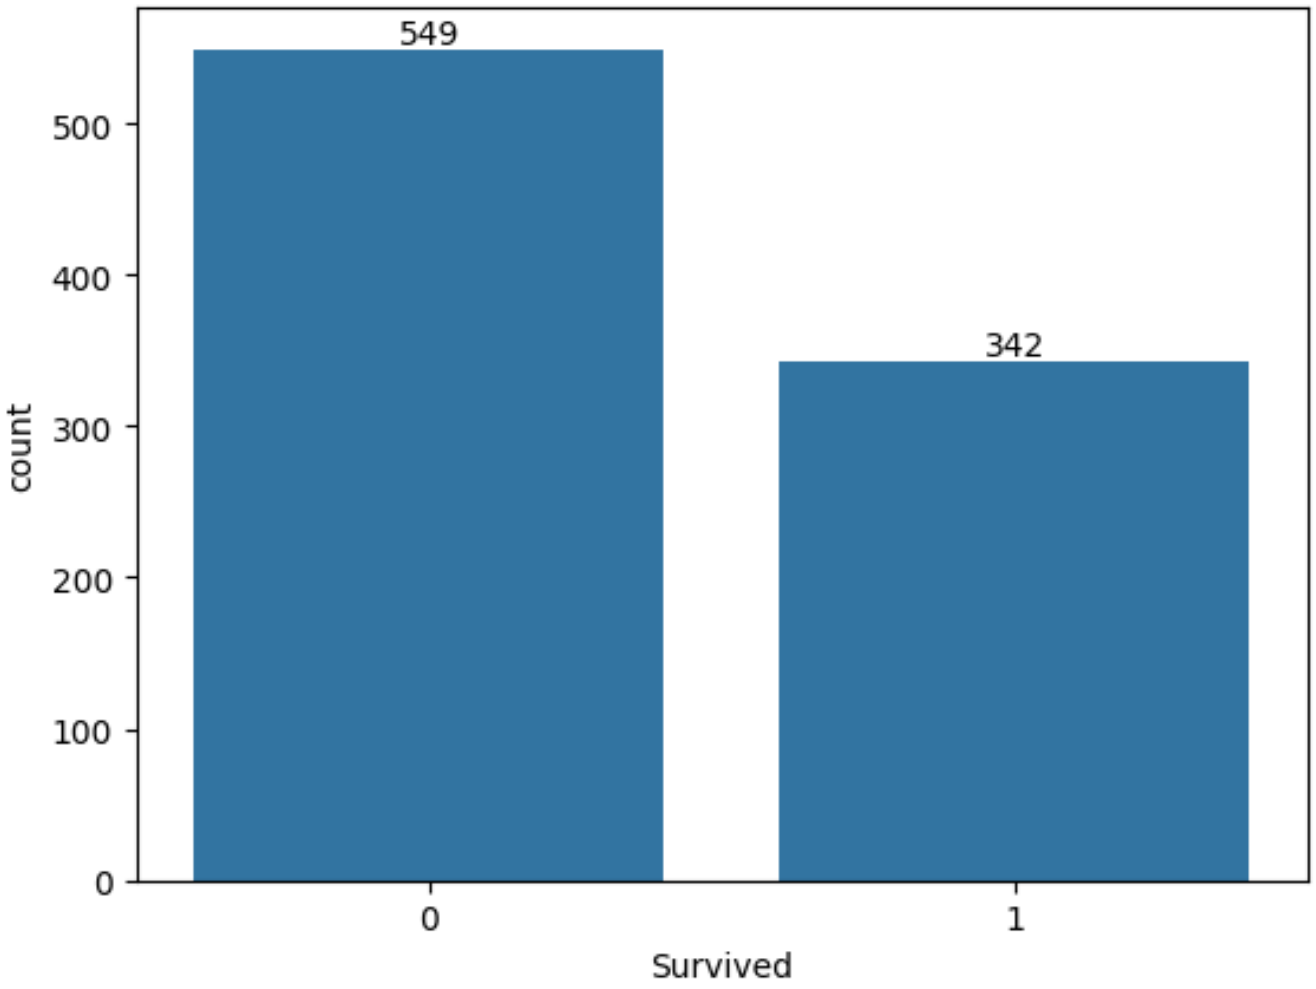
ارفع النوتبوك وtrain.csv إلى جلسة Colab، ثم نفذ الخلايا بالترتيب. ستكتب الملفات في مجلد العمل المؤقت؛ نزل المخرجات قبل انتهاء الجلسة. لم نعد نعتمد على مسار Drive شخصي.

توثيق النشر

خطوة GitHub يذكر كل تعديل مقارنة بالأصل. رفع CHANGELOG .بالإنجليزية يوضح الهدف والنتائج والتشغيل والحدود README منفصلة يجب تأكيد نجاحها برابط المستودع بعد النشر؛ وجود هذا التقرير لا يثبت أن الرفع تم.

Original 1: Survival counts

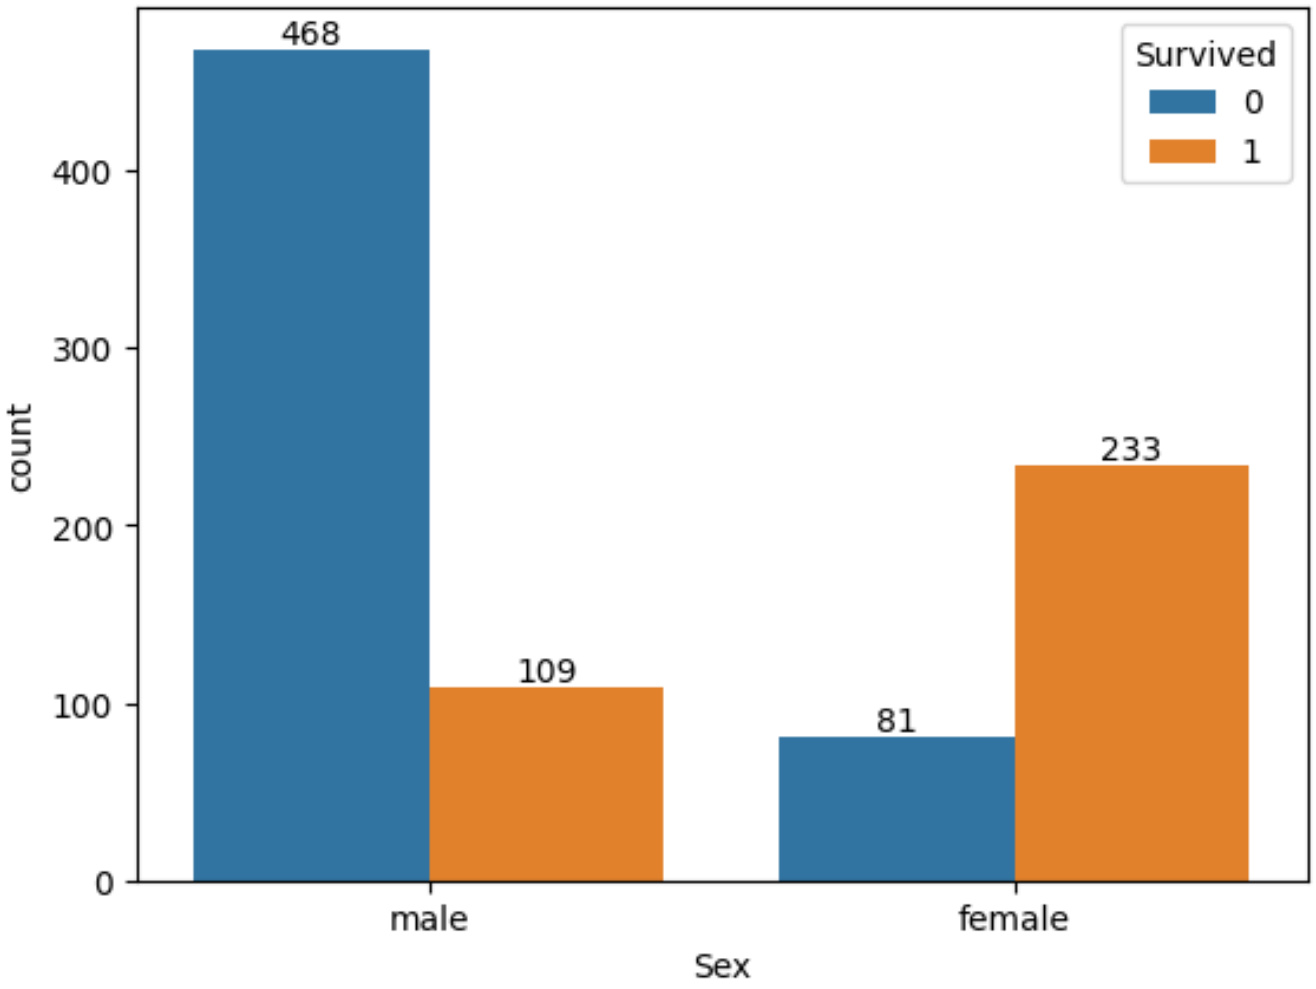
ملحق الرسومات الأصلية | محفوظة من مخرجات النوتبوك الأصلي



شرح الصورة الأصلية والتعديل المقابل

الرسم الأصلي يعرض Survived في عمودين مع أعداد فوقهما. المعنى مطابق للرسم الجديد الأول؛ النسخة الجديدة تضيف عنوانا ووصفا أوضح للمحاور وحفظا تلقائيا للصورة.

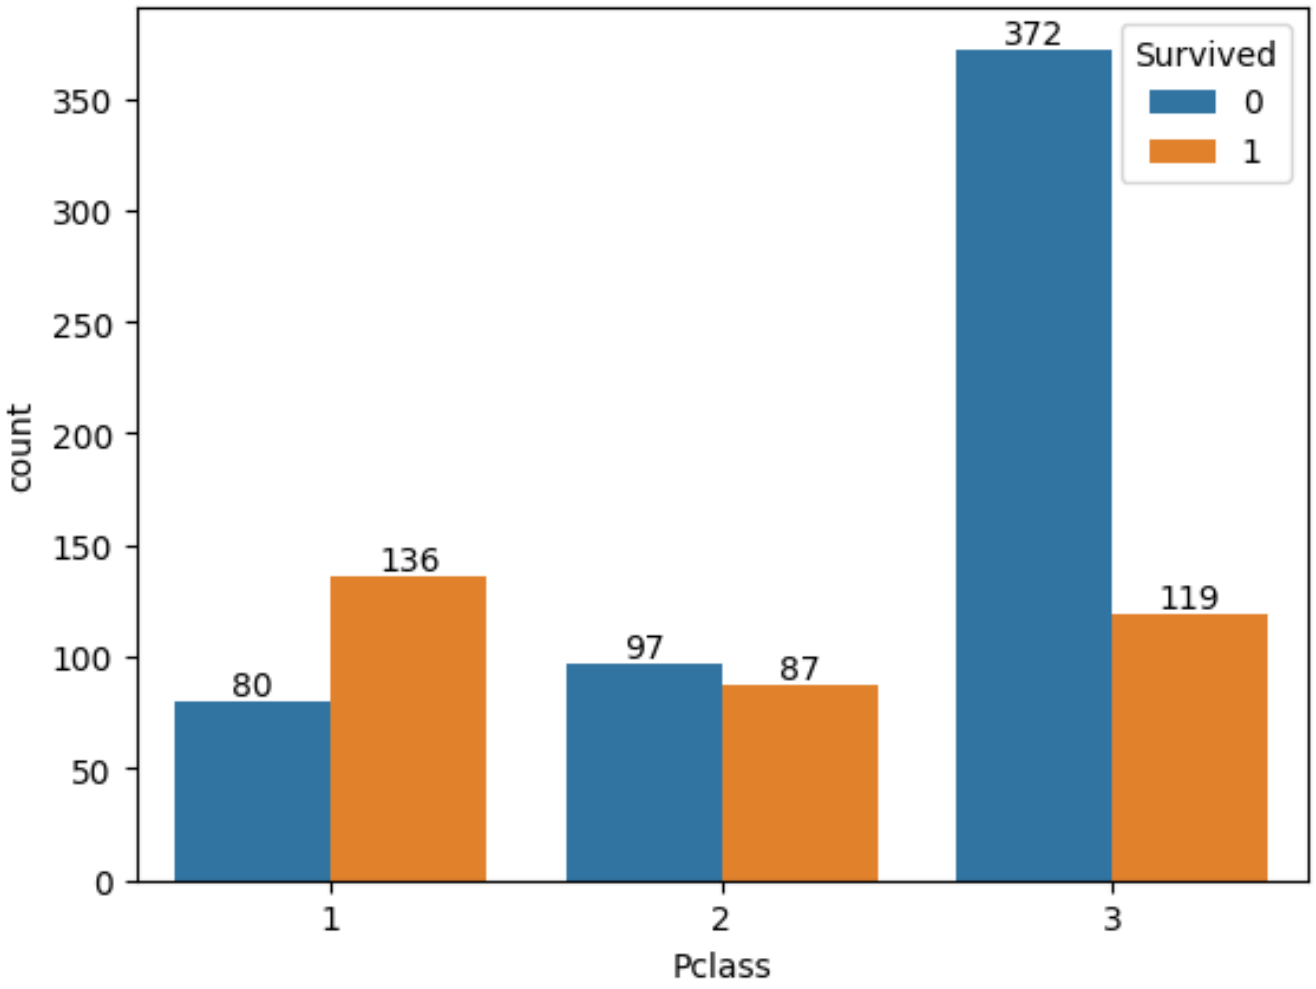
المصدر المحلي: figures/original/cell_31_figure_00.png



شرح الصورة الأصلية والتعديل المقابل

الرسم الأصلي يقارن أعداد الناجين وغير الناجين داخل كل جنس. لا يكفي اختلاف ارتفاع الأعمدة للمقارنة بين مجموعات مختلفة الحجم؛ لذلك أضفنا جدول نسب ورسم معدلات في النسخة الجديدة.

المصدر المحلي: figures/original/cell_31_figure_01.png

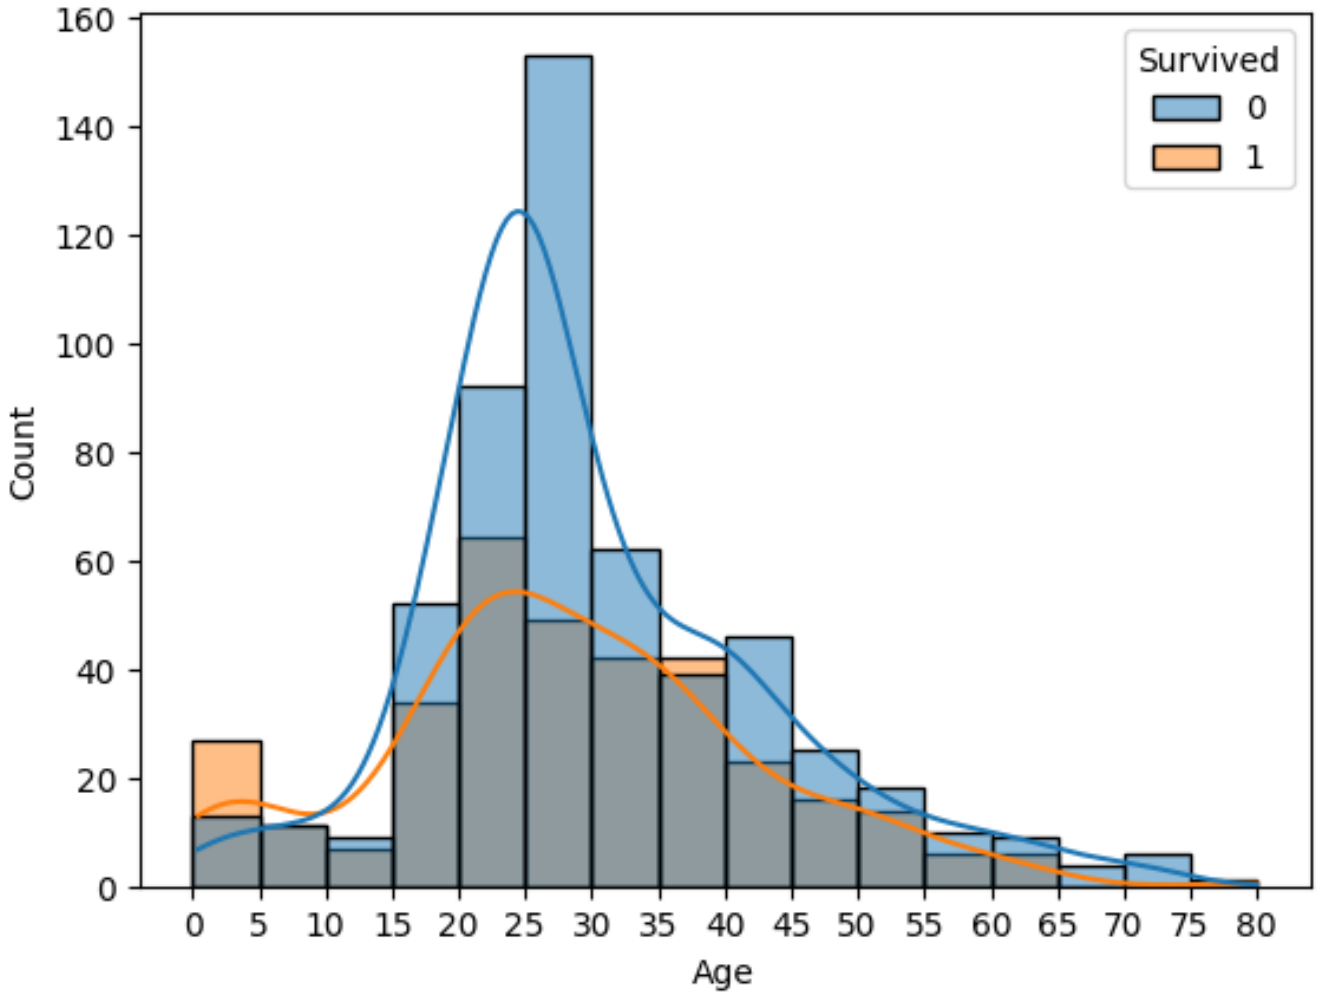


شرح الصورة الأصلية والتعديل المقابل

الرسم الأصلي يعرض درجة التذكرة وعلاقة الأعداد بالنجاة. نسخة التحسين تبقي المقارنة وتوضح دلالة Pclass وتعرض نسب النجاة والحجم لكل درجة.

المصدر المحلي: figures/original/cell_32_figure_00.png

Original 4: Age histogram



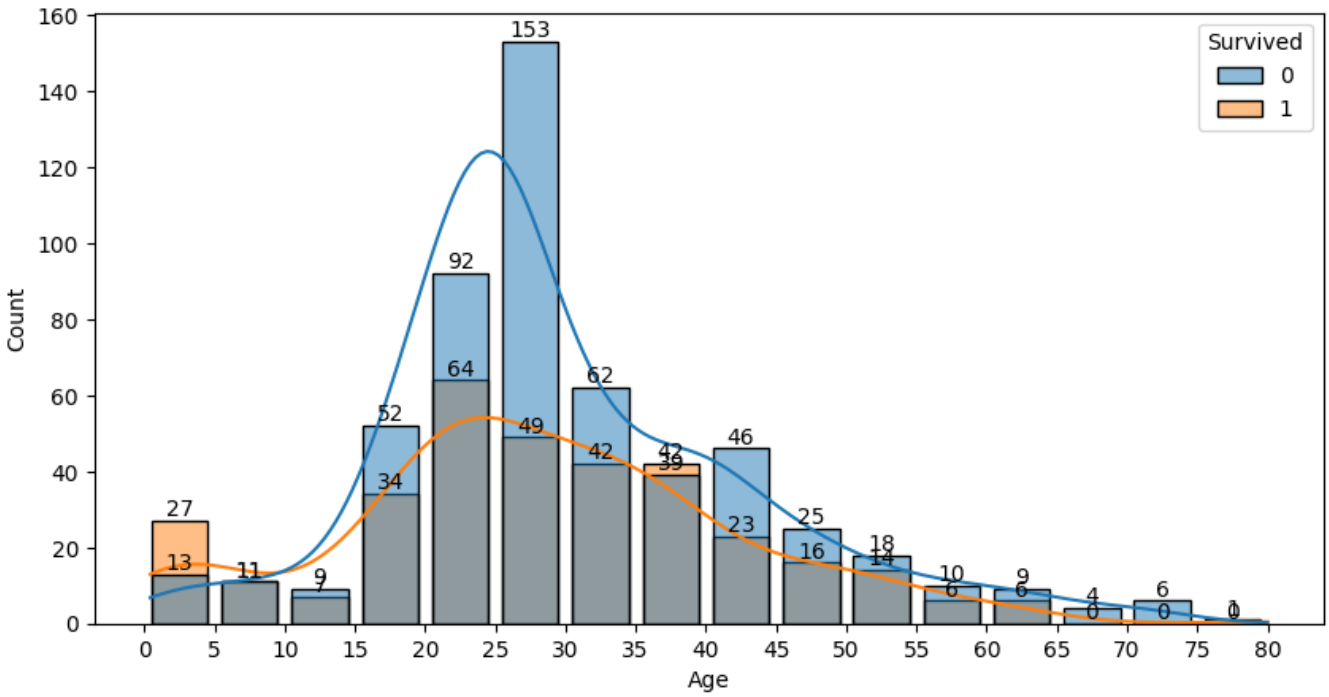
شرح الصورة الأصلية والتعديل المقابل

الرسم الأصلي يقسم العمر إلى نطاقات خمس سنوات ويعرض KDE. البيانات المرسومة تحتوي أعمارا مقدرة بوسيط المجموعة. النسخة الجديدة توضح هذا القيد وتضيف مقارنة بالأعمار المعروفة فقط.

المصدر المحلي: figures/original/cell_35_figure_00.png

Original 5: Labeled age histogram

ملحق الرسومات الأصلية | محفوظة من مخرجات النوتبوك الأصلي



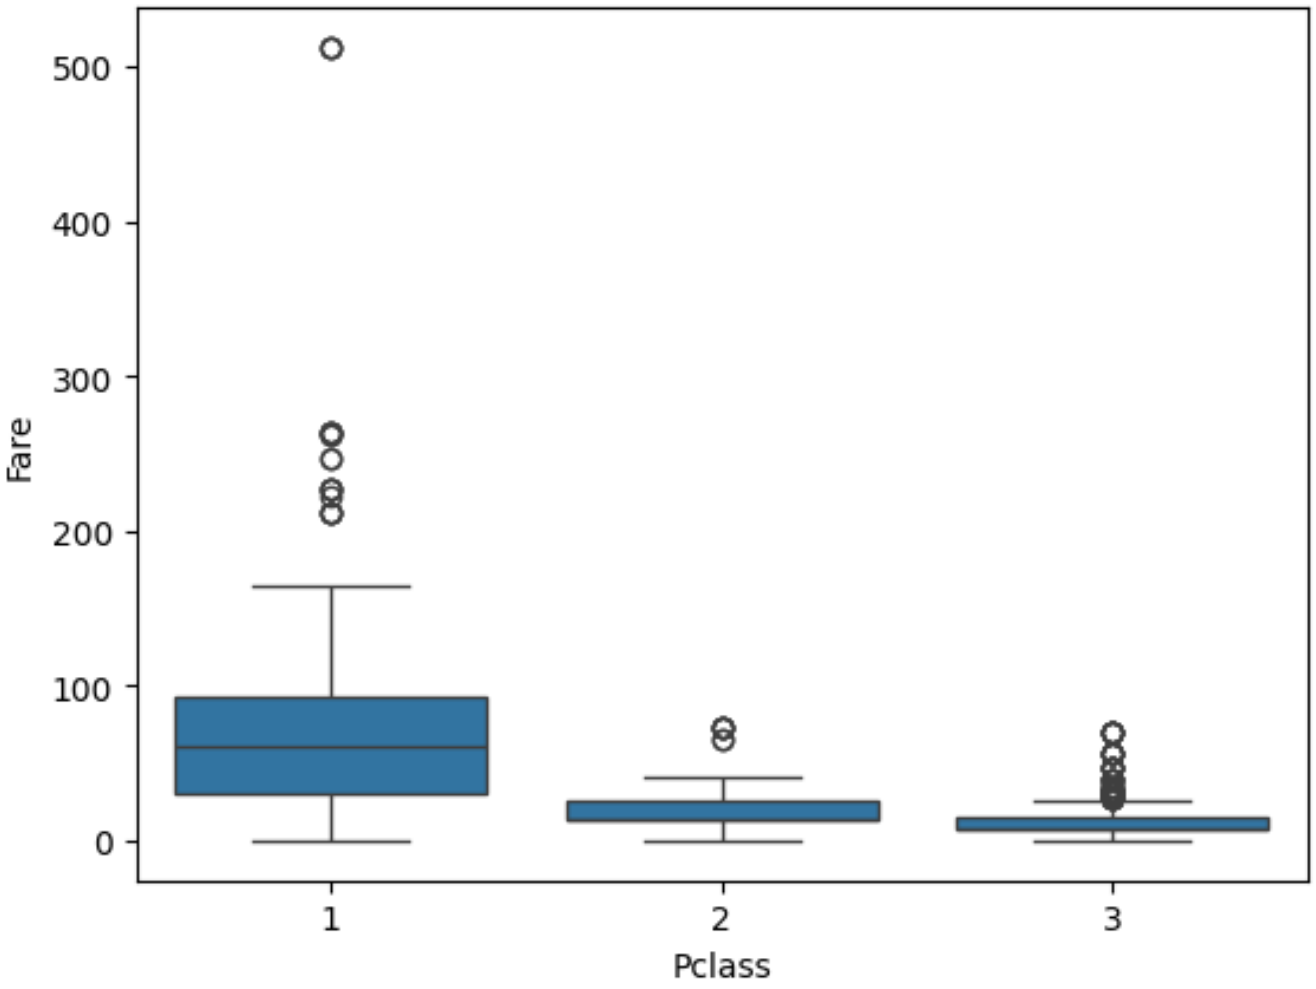
شرح الصورة الأصلية والتعديل المقابل

نسخة ثانية من توزيع العمر مع أرقام فوق الأعمدة؛ تعيد تقريبا نفس التحليل السابق وقد تزحم العرض. استبدلنا هذا التكرار برسم الأعمار المعروفة فقط، مع الاحتفاظ بهذه الصورة الأصلية هنا.

المصدر المحلي: figures/original/cell_36_figure_00.png

Original 6: Fare boxplot

ملحق الرسومات الأصلية | محفوظة من مخرجات النوتبوك الأصلي



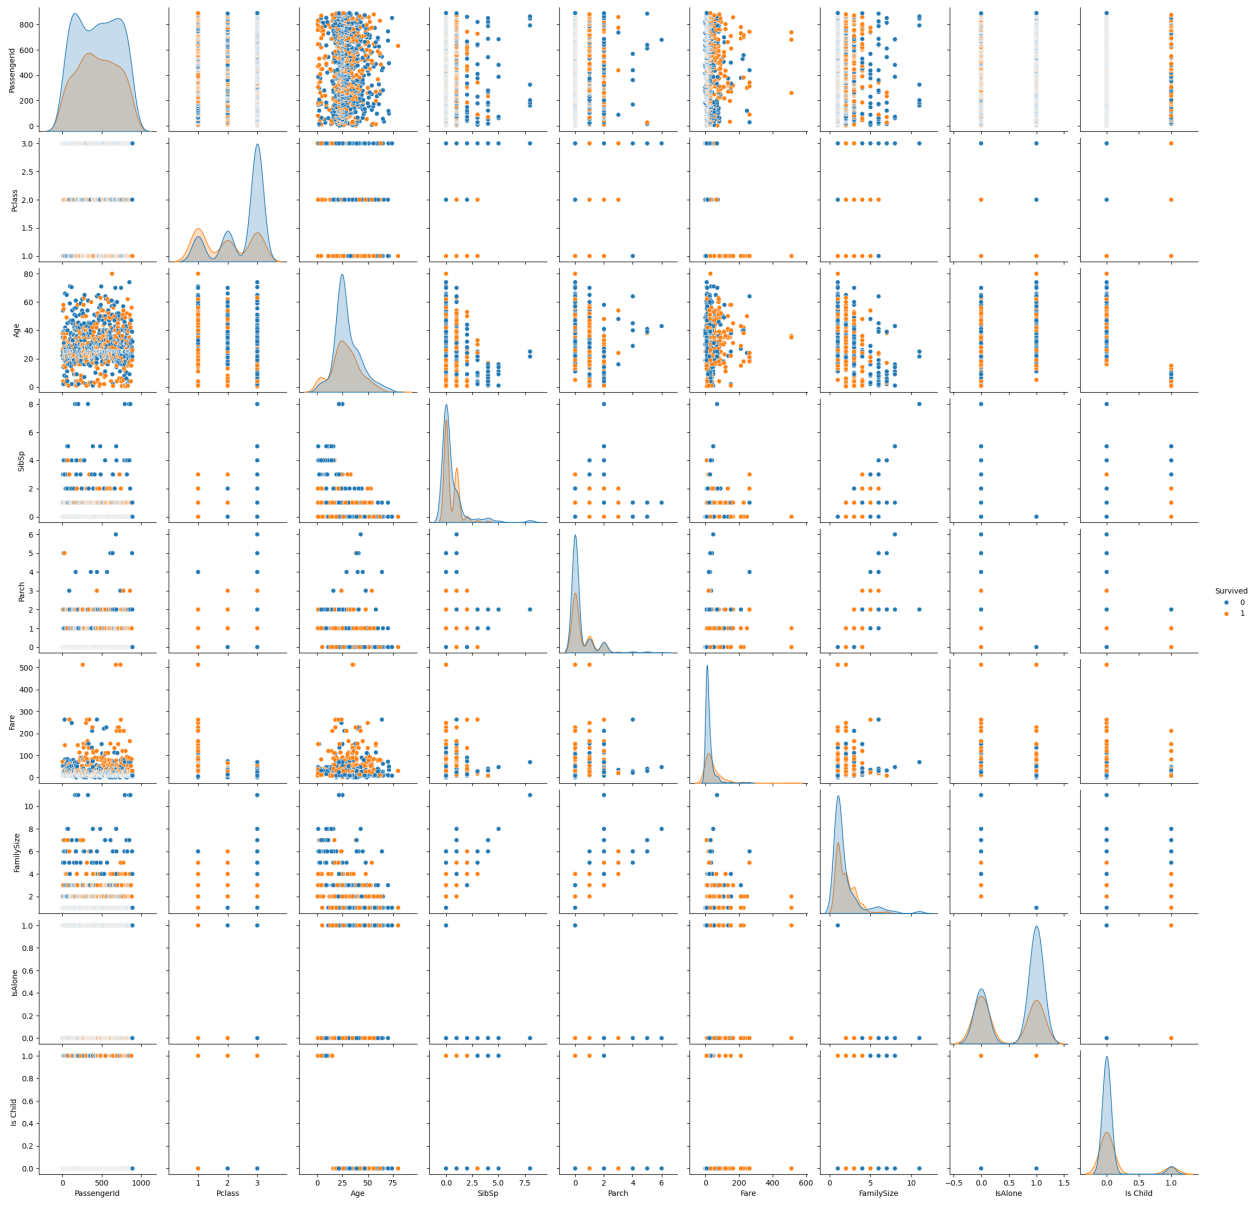
شرح الصورة الأصلية والتعديل المقابل

الصندوق والشوارب يعرضان توزيع Fare حسب الدرجة. النقاط البعيدة ليست دليل أخطاء. أضفنا لوحة بمقياس symlog لتوضيح التفاصيل دون حذف أسعار مرتفعة.

المصدر المحلي: figures/original/cell_37_figure_00.png

Original 7: Full pairplot

ملحق الرسومات الأصلية | محفوظة من مخرجات النوتبوك الأصلي



شرح الصورة الأصلية والتعديل المقابل

الرسم الأصلي يضم كل الأعمدة الرقمية، بما فيها PassengerId وخصائص ثنائية، فيصبح مزدحما جدا. كل لوحة تربط متغيرين واللون يوضح النجاة؛ القطر يعرض التوزيع. النسخة الجديدة تقصر الرسم على Age وFare وFamilySize لتحسين القراءة. الصورة الأصلية الكاملة محفوظة بدقتها في figures/original، ويمكن تكبيرها لقراءة اللوحات الصغيرة.

المصدر المحلي: figures/original/cell_38_figure_00.png