تقرير تحليل بيانات Titanic

ملخص تنفيذي

تم تحليل بيانات 891 راكبا، بهدف فهم جودة البيانات وأنماط النجاة. يتناول التقرير تنظيف القيم الناقصة، إنشاء خصائص مرتبطة بالأسرة والعمر، ثم تفسير الرسومات السبعة التي ينتجها النوتبوك.

أهم النتائج

نجا 342 راكبا بنسبة 38.38%، ولم ينج 549. نجاة الإناث 74.20% مقابل 18.89% للذكور. نجاة الدرجة الأولى 62.96%، والثانية 47.28%، والثالثة 24.24%.

حالة التسليم ونطاقه

يتضمن التسليم النوتبوك والبيانات الخام والصور السبع وتقريري التحليل بالعربية والإنجليزية. يقتصر العمل على تنظيف البيانات والتحليل الوصفي، ولا يتضمن نموذج تنبؤ أو تقديرا سببيا.

قراءة النتائج

النسب تخص ملف البيانات محل الدراسة. قد تتداخل الدرجة والجنس والعمر وظروف التسجيل؛ لذلك لا تعني الفروق أن متغيرا منفردا سبب النجاة.

1. نطاق البيانات وفحص الجودة

بنية الملف

يحتوي train.csv على 891 صفا و12 عمودا. كل صف يمثل راكبا. يعرض الكود head وinfo وdescribe لفهم البنية والأنواع والإحصاءات الوصفية.

تعريف الحقول

Survived: نجا صفر لم ينج وواحد Pclass: الثالثة إلى الأولى من التذكرة درجة .Sex وAge: بالسنوات العمر والجنس .SibSp: الأشقاء أو الزوج/الزوجة على السفينة. Parch: الآباء والأبناء. Fare: سعر التذكرة المسجل. Cabin: الكابينة إن سجلت. Embarked: ميناء الصعود. PassengerId وName وTicket حقول تعريفية.

القيم الناقصة والتكرارات

العمر مفقود في 177 سجلا (19.87%)، والكابينة في 687 (77.10%)، وميناء الصعود في سجلين (0.22%). لا توجد صفوف متطابقة مكررة في الملف الحالي. يحسب الكود التكرارات ولا يحذف صفوفا.

حدود المصدر

هذه عينة التدريب المصاحبة للمشروع، وليست سجلا لجميع ركاب السفينة. لا تتوافر ضمن الملفات وثيقة مستقلة توثق مصدر التنزيل وشروط استخدام البيانات. قد يمثل Fare حجزا مشتركا ولا يعبر عن دخل الراكب.

2. خطوات التنظيف والخصائص

إعداد نسخة للعمل

ينشئ الكود df_clean من df، ويزيل المسافات من أسماء الأعمدة ومن Embarked، ويحول النص الفارغ في Embarked إلى قيمة مفقودة. يقرأ train.csv من مجلد العمل نفسه.

تعويض المفقود

يحسب الكود منوال Embarked، ثم يستخدم S صراحة لملء القيمتين المفقودتين. يملأ 177 عمرا بوسيط المجموعة المشتركة لـPclass وSex. لا توجد علامة منفصلة تحفظ كون العمر مقدرا، ولذلك يجب الرجوع إلى البيانات الخام عند الفصل بين المسجل والمقدر.

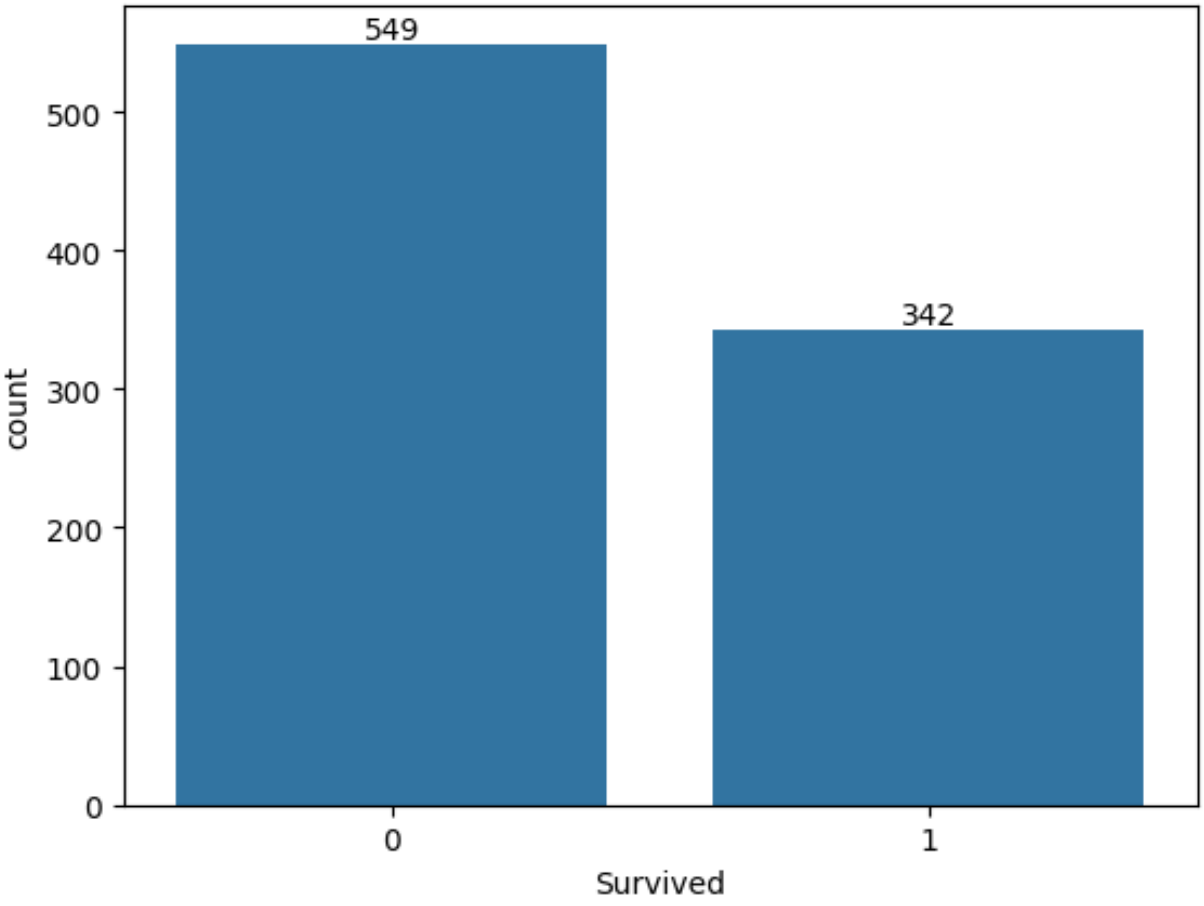
الكابينة وأسعار التذاكر

يظل Cabin موجودا وبداخله 687 قيمة مفقودة. سطرا إضافة Has_Cabin وحذف Cabin معلقان ولا ينفذان. بالنسبة لـFare، يحسب الكود الحد Q3 + 1.5 × IQR = 65.6344، ويعرض 116 قيمة فوقه دون حذفها أو إضافة علامة لها.

خصائص الأسرة والطفل

Age يعتمد على Is Child يساوي واحدا عند حجم أسرة مسجل يساوي واحدا. العمود IsAlone .1 + Parch + SibSp = FamilySize وعدده 83. التعليق فوقه يشير إلى >16، لكن العملية المنفذة فعليا هي أقل من 16. يصبح الجدول أثناء التنفيذ 15 عمودا، ولا يصدر الكود CSV منظفا.

3.1 أعداد الناجين وغير الناجين



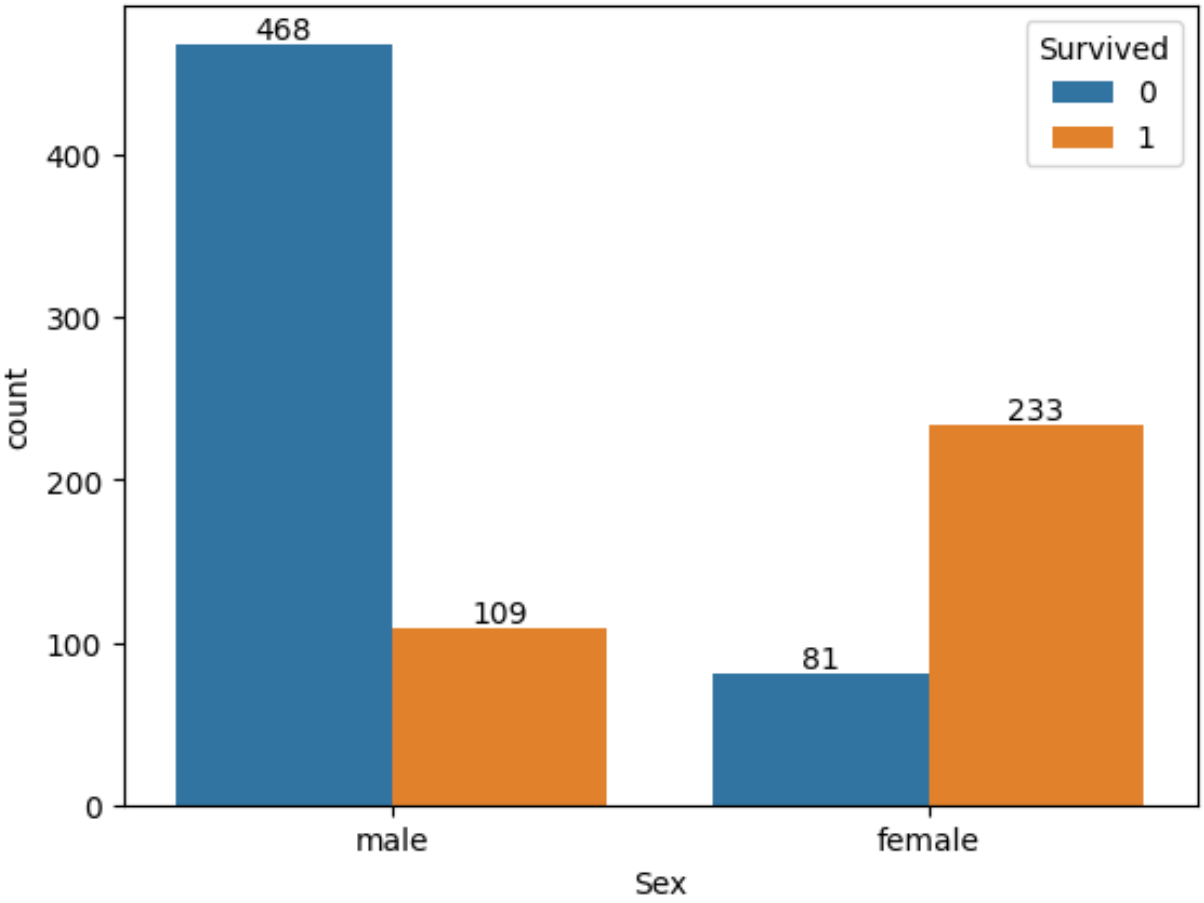
قراءة الرسم

المحور الأفقي يعرض Survived بقيمتي صفر وواحد، والرأسي عدد الركاب. الرقم فوق كل عمود يحدد العدد الفعلي. صفر يعني لم ينج، وواحد يعني نجا.

النتيجة والتفسير

549 لم ينجوا مقابل 342 ناجيا. نسبة النجاة العامة 38.38%. النتيجة غير متوازنة عدديا، ويستخدم هذا المعدل كمرجع وصفي للمقارنات التالية؛ لا يمثل احتمالا ثابتا لكل فرد.

3.2 الجنس والنجاة



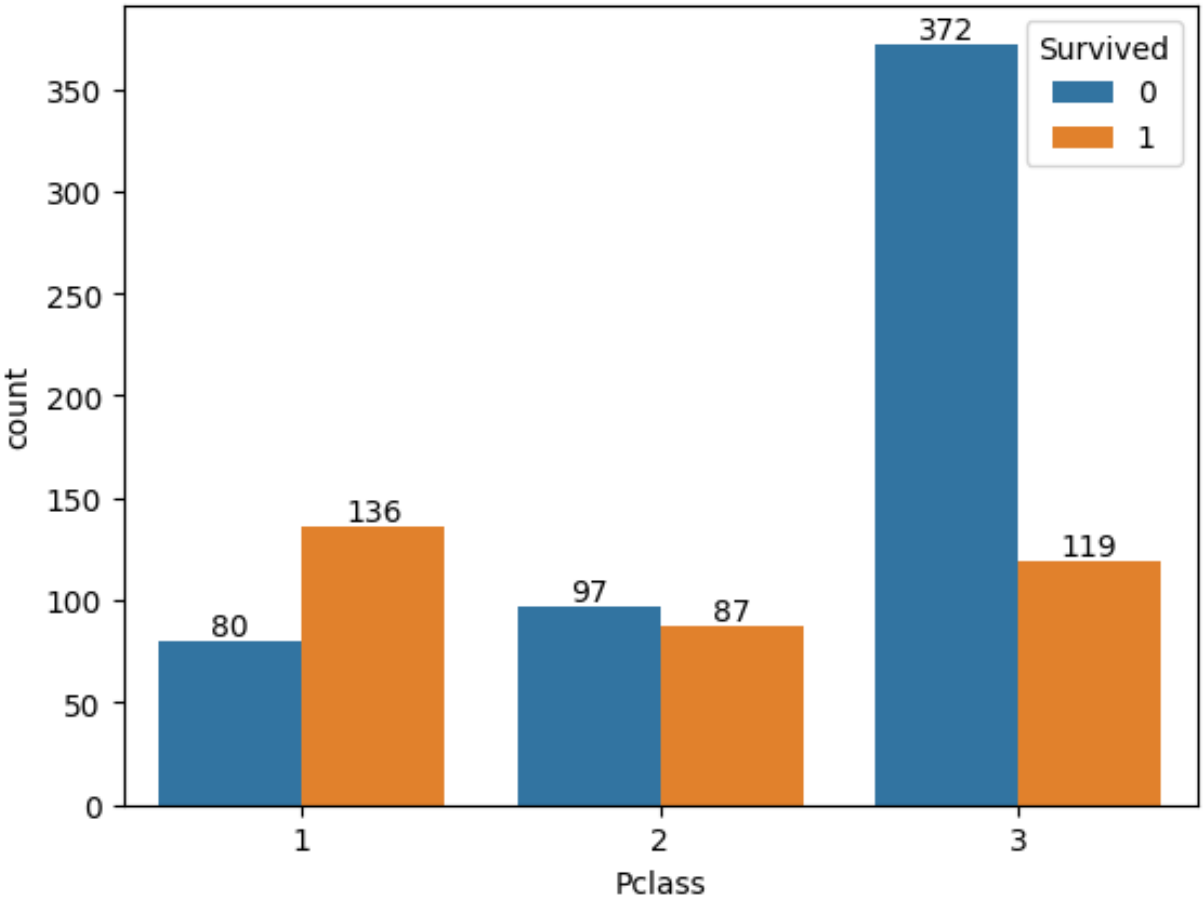
قراءة الرسم

المحور الأفقي يعرض male وfemale، واللون يوضح النتيجة: الأزرق صفر لم ينج، والبرتقالي واحد نجا. نقارن العمودين داخل كل مجموعة، مع مراعاة اختلاف حجم المجموعتين.

النتيجة والتفسير

الذكور: 468 لم ينجوا و109 نجوا من أصل 577، بنسبة نجاة 18.89%. الإناث: 81 لم ينجين و233 نجين من أصل 314، بنسبة نجاة 74.20%. فرق المعدلين 55.31 نقطة مئوية. النسب محسوبة لتفسير الأعداد المرسومة؛ لا يعزل الرسم أثر العمر أو الدرجة.

3.3 درجة التذكرة والنجاة



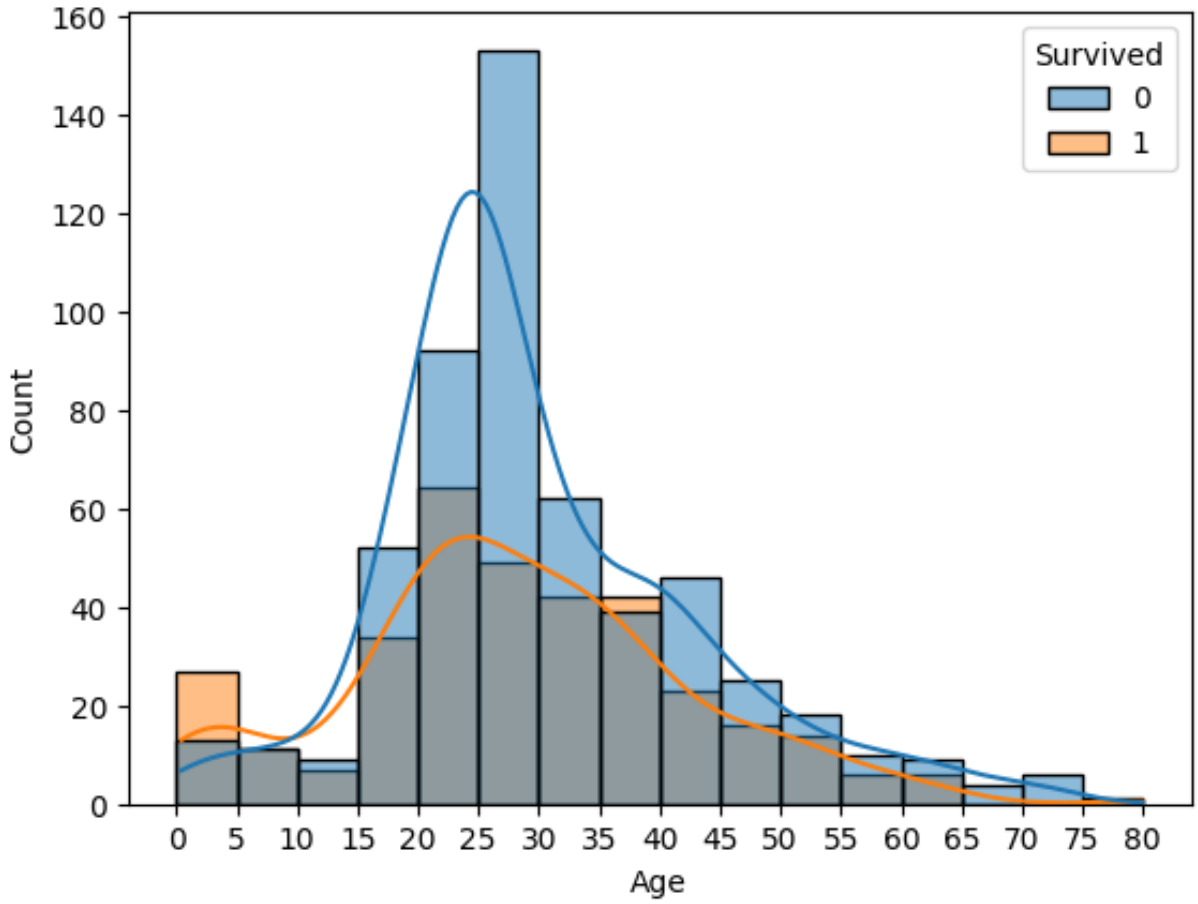
قراءة الرسم

يعرض المحور الأفقي Pclass من 1 إلى 3، والرأسي عدد الركاب. الأزرق لغير الناجين والبرتقالي للناجين. يجب مقارنة النسب داخل الدرجة لأن أعداد الركاب تختلف بين الدرجات.

النتيجة والتفسير

الأولى: 136 ناجيا و80 لم ينجوا، بنسبة 62.96%. الثانية: 87 ناجيا و97 لم ينجوا، بنسبة 47.28%. الثالثة: 119 ناجيا و372 لم ينجوا، بنسبة 24.24%. الثالثة تضم العدد الأكبر من الركاب (491). الفروق وصفية وقد تتداخل مع الجنس والعمر وموقع الراكب.

3.4 توزيع الأعمار حسب النجاة



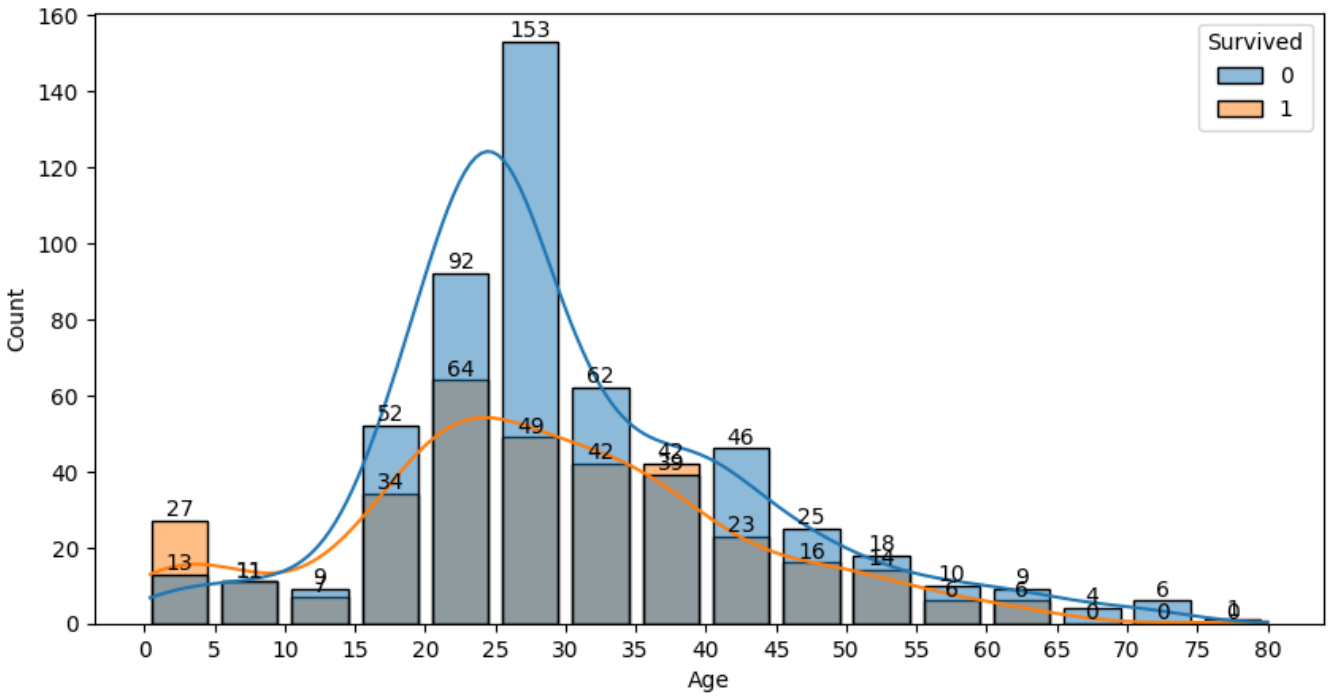
قراءة الرسم

المحور الأفقي العمر بالسنوات في نطاقات عرضها خمس سنوات من صفر إلى 80، والرأسي عدد الركاب. اللون يميز النجاة، والخطوط الملساء KDE تلخص شكل التوزيع. تداخل الأعمدة يسمح برؤية المجموعتين لكنه قد يحجب أجزاء منهما.

النتيجة والتفسير

تتركز أعمار كثيرة في الشباب والبالغين. يتضمن الرسم 177 عمرا مقدرا بوسيط المجموعة، وقد يصنع التعويض قمما عند أعمار معينة. ارتفاع عدد ركاب عمر محدد لا يساوي ارتفاع احتمال النجاة؛ خطوط KDE ليست احتمالات نجاة أو فترات ثقة.

3.5 توزيع الأعمار مع أعداد الأعمدة



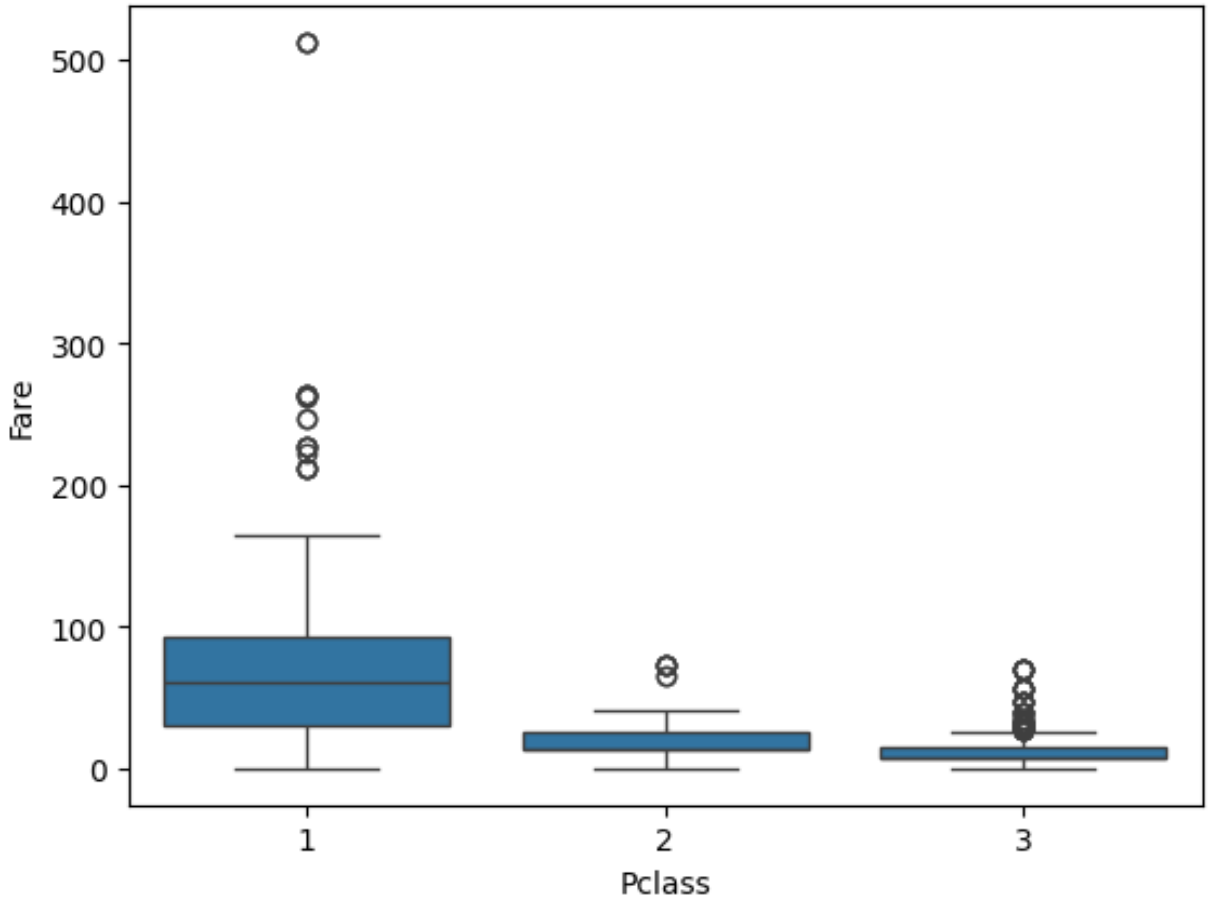
قراءة الرسم

هذا عرض آخر لنفس بيانات العمر بعد التعويض، مع حجم صورة مختلف وأرقام فوق الأعمدة وتضييق الأعمدة باستخدام shrink. تبقى النطاقات خمسية السنوات والألوان ممثلة لنتيجة النجاة.

النتيجة والتفسير

الأرقام تساعد على قراءة عدد الركاب في كل نطاق، لكن ازدحامها يحتاج إلى تكبير الصورة. يستخدم الرسمان نفس البيانات؛ لا يمثل هذا فحصا للأعمار المسجلة فقط أو تحليلا مستقلا. تنطبق عليه قيود تعويض العمر وتداخل الأعمدة نفسها.

3.6 أسعار التذاكر حسب الدرجة



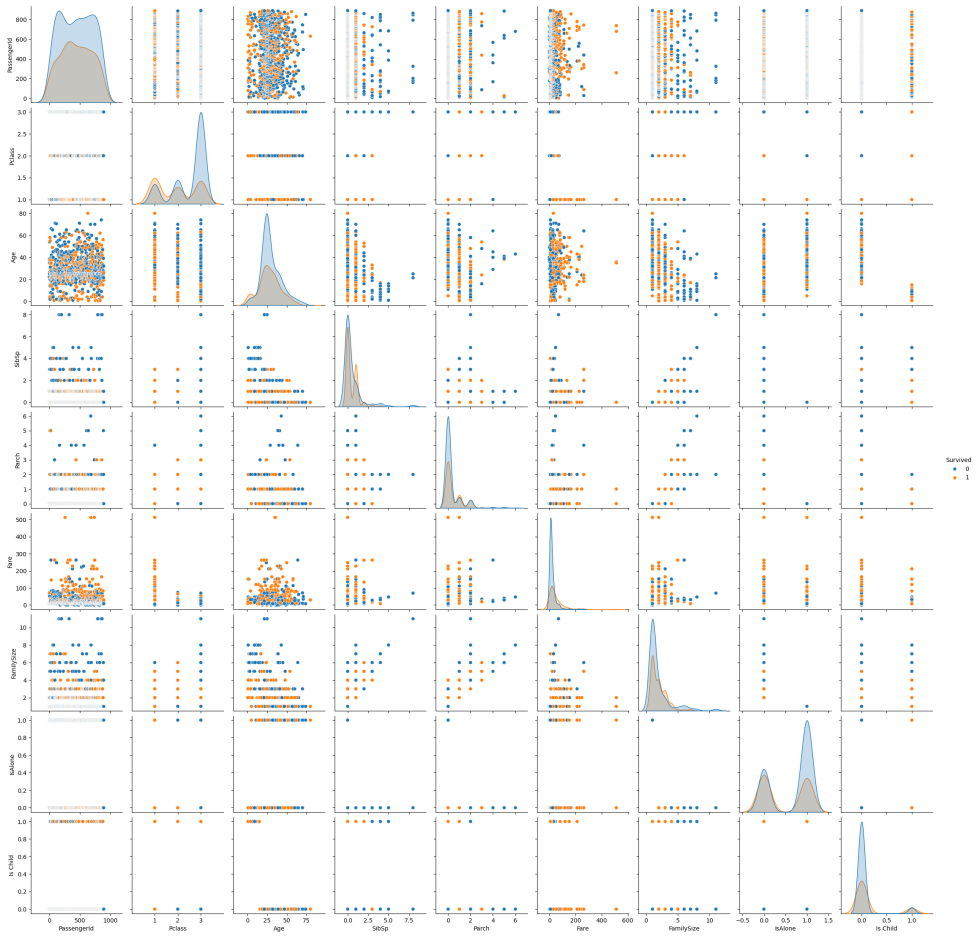
قراءة الرسم

المحور الأفقي درجة التذكرة والرأسي Fare بالمقياس الأصلي. الخط داخل الصندوق هو الوسيط، وحداه الربيعان الأول والثالث. الشوارب تمتد لأبعد قيمة داخل 1.5 IQR من حدود الصندوق، والنقاط خارجها قيم إحصائية متطرفة.

النتيجة والتفسير

تظهر الدرجة الأولى أسعارا أعلى وتشتتا أكبر، مع قيمة قصوى تقارب 512.33. النقاط البعيدة ليست أخطاء مؤكدة. شوارب الرسم تحسب داخل كل درجة؛ أما قائمة القيم المرتفعة في الكود فتستخدم حدا عاما قدره 65.6344 للملف كله. لا يحذف الكود أسعارا مرتفعة، ولا يستخدم الرسم مقياسا لوغاريتميا.

3.7 مصفوفة العلاقات Pairplot



قراءة الرسم

كل لوحة خارج القطر تعرض متغيرين؛ اسم العمود يحدد المحور الأفقي واسم الصف يحدد الرأسي. القطر يعرض التوزيع. المتغيرات التسعة هي الأزرق لغير الناجين والبرتقالي .Is Child وIsAlone وFamilySize وFare وParch وSibSp وAge وPclass وPassengerId للناجين.

النتيجة والتفسير

توجد مناطق تداخل واضحة بين النتيجتين. PassengerId معرف لا يفسر النجاة، والمتغيرات الثنائية والمتقطعة تصنع تجمعات وخطوطا طبيعية. العمر يتضمن قيما مقدرة، وFare شديد الالتواء. لا يثبت الشكل علاقة سببية أو دقة تنبؤ. المصفوفة كبيرة؛ استخدم صورة PNG المصاحبة بتكبير مناسب لقراءة اللوحات الصغيرة.

4. الخلاصة والقيود والتوصيات

خلاصة النتائج

تختلف نسب النجاة حسب الجنس والدرجة في هذه العينة. يحسب الكود أيضا نجاة المسافرين وحدهم (30.35%) ومن لديهم أقارب مسجلون (50.56%)، لكنه لا يرسم هذه المقارنة في صورة مستقلة. IsAlone يصف الأقارب في SibSp وParch، وليس الأصدقاء أو جميع المعارف.

قيود يجب مراعاتها

يبقى Cabin ناقصا بكثرة، ولا توجد خصائص لتوافره. العمر المقدر لا يتم تمييزه بعلامة منفصلة، ويؤثر في شكل توزيع العمر. لا توجد اختبارات دلالة أو فترات ثقة أو نماذج مضبوطة. لا يمثل ملف التدريب كل ركاب السفينة، ولا تثبت الرسومات أسباب النجاة.

توصيات استخدام البيانات

احتفظ بالمصدر الخام، ووثق تعويض العمر ونقص Cabin عند مشاركة النتائج. استخدم الأعداد والنسب معا، ولا تحذف الأسعار المرتفعة دون مراجعة المصدر. عند تطوير نموذج لاحقا، قسم البيانات أولا وتعلم التعويض من التدريب وحده. هذه توصيات مستقبلية وليست خطوات إضافية منفذة في الكود.

5. الملفات وإعادة التشغيل

قائمة التسليم

Titanic_cleaning.ipynb: الكود والتحليل ومخرجاته.

train.csv: البيانات الخام.

figures: سبع صور مستخرجة من مخرجات النوتبوك.

output/pdf: تقريران بالعربية والإنجليزية.

output: نسختان نصيتان من التقريرين.

requirements.txt وREADME.md: التعليمات والمكتبات.

التشغيل

ثبت المكتبات في requirements.txt، وافتح النوتبوك من مجلد المشروع حيث يوجد train.csv، واختر Restart ثم Python kernel إلى مجلد العمل. ينتج الكود الرسومات والجداول داخل النوتبوك، ولا يحفظ الصور أو train.csv ارفع Colab في Kernel and Run All. تلقائيا CSV.

التحقق والتوثيق

مرجع التحقق هو تنفيذ النوتبوك وقراءة بياناته: 891 راكبا و342 ناجيا، وبقاء 687 قيمة Cabin مفقودة، وإنتاج سبع رسومات. تاريخ التقرير 19 أكتوبر 2026. الأرقام الوصفية في الشرح محسوبة من البيانات لتفسير الرسومات، ولا تعني وجود رسوم أو اختبارات إضافية.