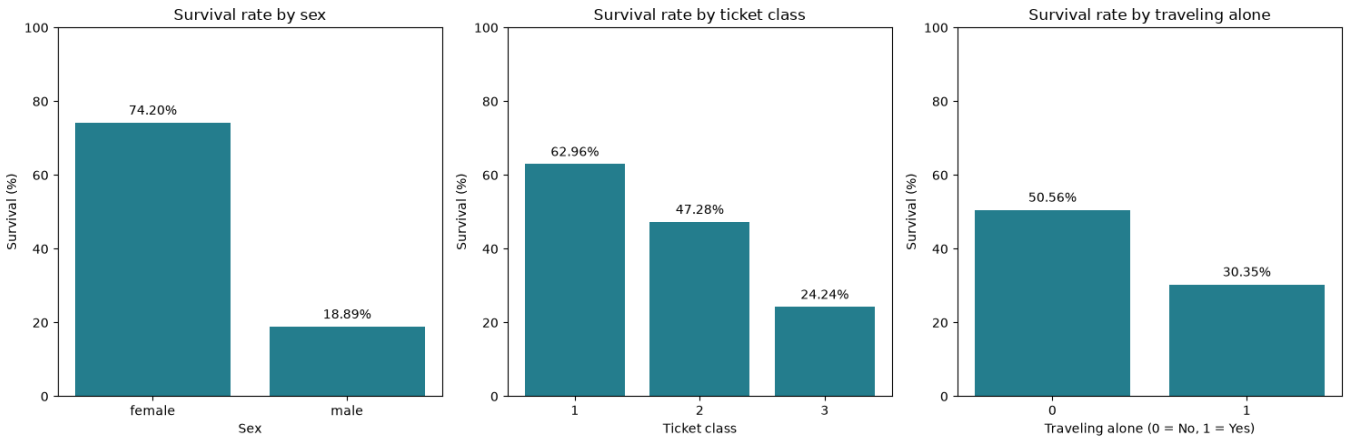
أنماط النجاة في لمحة

النتائج الرئيسية | تحليل 891 سجل راكب

38.38%	342	891
نسبة النجاة	ناجيا	راكبا

الرسم 1: مقارنة معدلات النجاة



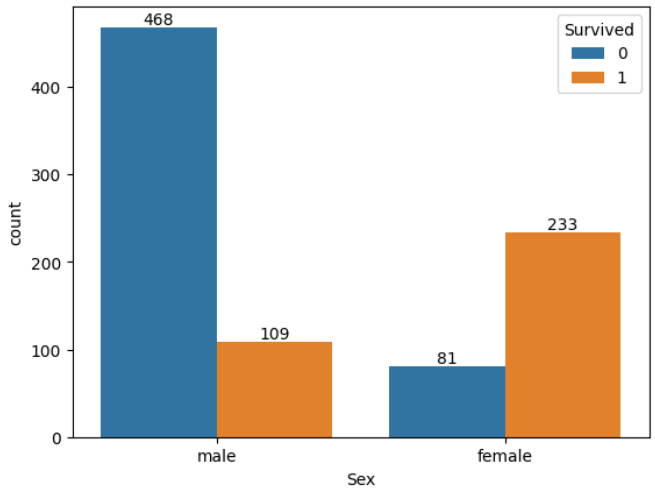
المحور الرأسي يعرض نسبة الناجين داخل كل مجموعة، والنسبة مكتوبة فوق العمود. بلغ معدل نجاة الإناث 74.20% مقابل 18.89% للذكور. انخفض المعدل من 62.96% في الأولى إلى 24.24% في الثالثة. نجاة من معهم أقارب مسجلون 50.56% مقابل 30.35% للمنفردين. هذه ارتباطات وصفية وليست أسبابا مؤكدة.

ما الذي يبرز؟

أكبر فرق ظاهر هو بين الجنسين، مع تدرج واضح حسب درجة التذكرة. يوضح التقرير أولا الرسومات الثمانية ونتائجها، ثم يشرح جودة البيانات والتنظيف والقيود وخطوات التشغيل.

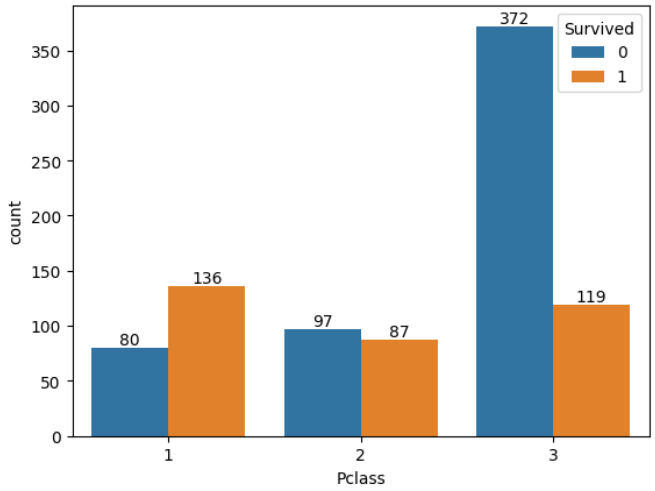
التحليل وصفي؛ الفروق لا تثبت السببية ولا تمثل دقة نموذج تنبؤ.

الرسم 2: النجاة حسب الجنس



الأزرق لغير الناجين والبرتقالي للناجين. من أصل 314 أنثى نجت 233، ومن أصل 577 ذكرا نجا 109. فرق معدلي النجاة 55.31 نقطة مئوية. اختلاف حجم المجموعتين يجعل النسب ضرورية بجانب الأعداد؛ ولا تعزل المقارنة أثر الدرجة أو العمر.

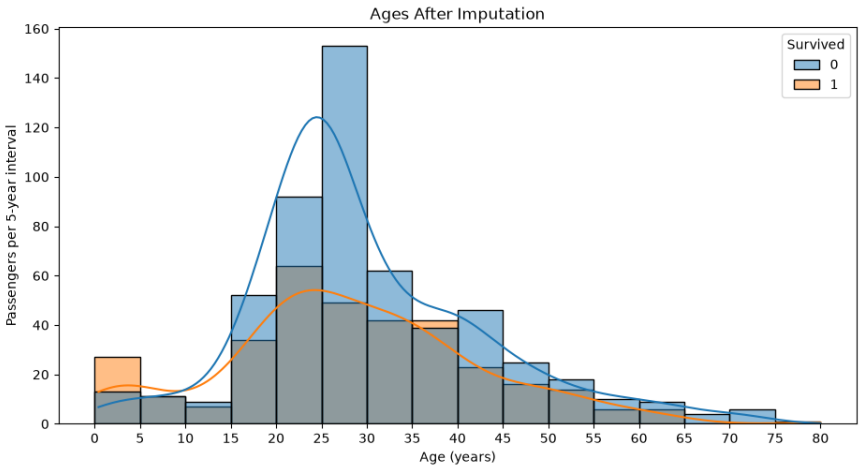
الرسم 3: النجاة حسب درجة التذكرة



الأولى: 136 ناجيا من 216 (62.96%). الثانية: 87 من 184 (47.28%). الثالثة: 119 من 491 (24.24%). الثالثة تضم العدد الأكبر من الركاب وأقل معدل نجاة في العينة. ارتفاع عدد الوفيات يحتاج إلى قراءة حجم المجموعة؛ النتيجة لا تثبت أثر الدرجة مستقلا عن العوامل الأخرى.

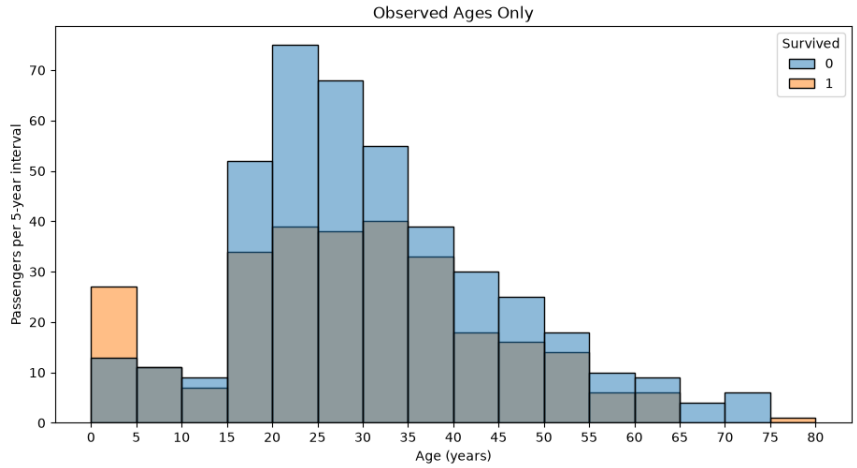
العمر: أثر تعويض القيم الناقصة

الرسم 4: الأعمار بعد تعويض المفقود



كل عمود يمثل نطاقا عمره خمس سنوات. يشمل الرسم 891 راكبا، منهم 177 عوضت أعمارهم بوسيط مجموعة الجنس والدرجة. خطوط KDE تلخص شكل التوزيع وليست معدلات نجاة. قد يصنع التعويض قمما عند أعمار الوسيط؛ لذلك نقارنه بالأعمار المسجلة فقط.

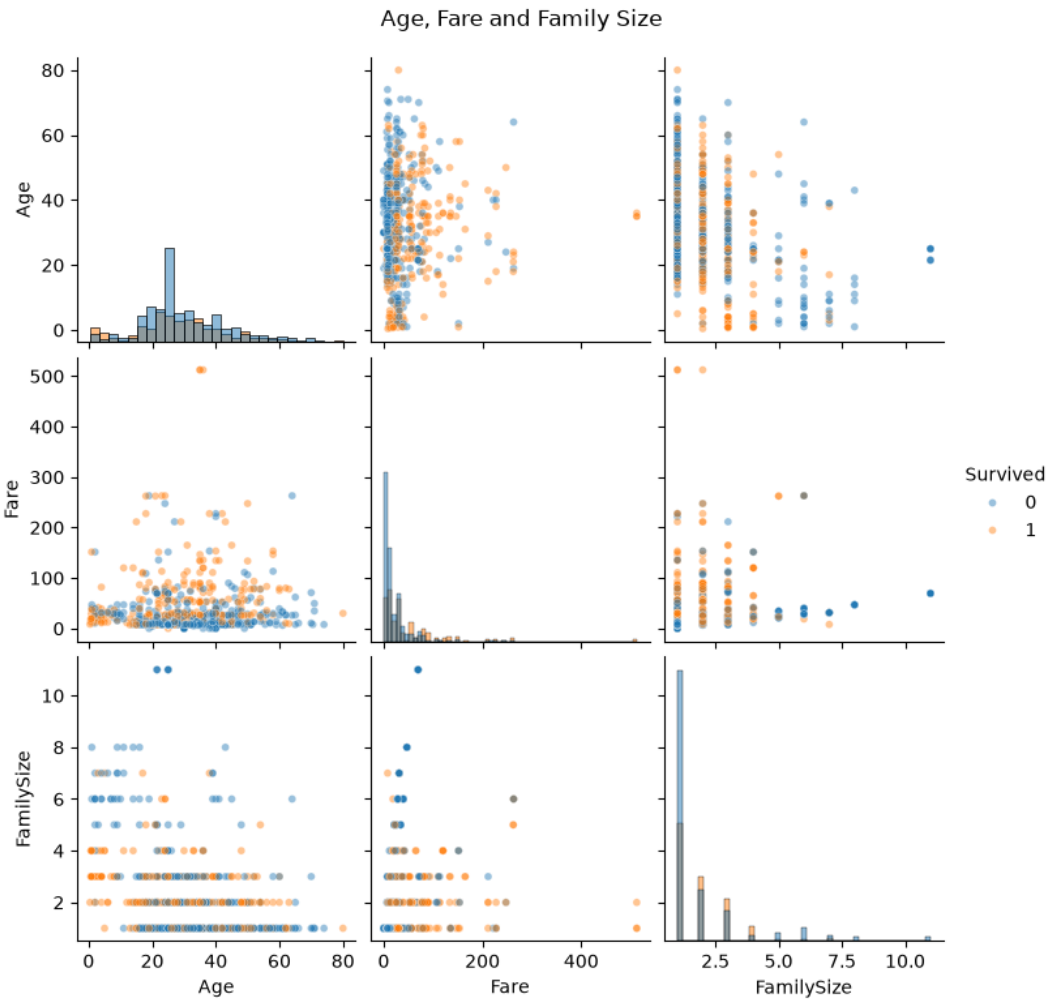
الرسم 5: الأعمار المسجلة فقط



يعرض الرسم 714 عمرا معلوما في البيانات الخام، ويستبعد 177 عمرا مقدرا من هذه الصورة فقط. لم تحذف صفوف من البيانات المنظفة. اختلاف الشكل يوضح حساسية التوزيع للتعويض، لكنه لا يلغي تحيز غياب العمر؛ المعروف قد يختلف عن المفقود.

العلاقة بين العمر والسعر والأسرة

الرسم 6: العمر والسعر وحجم الأسرة



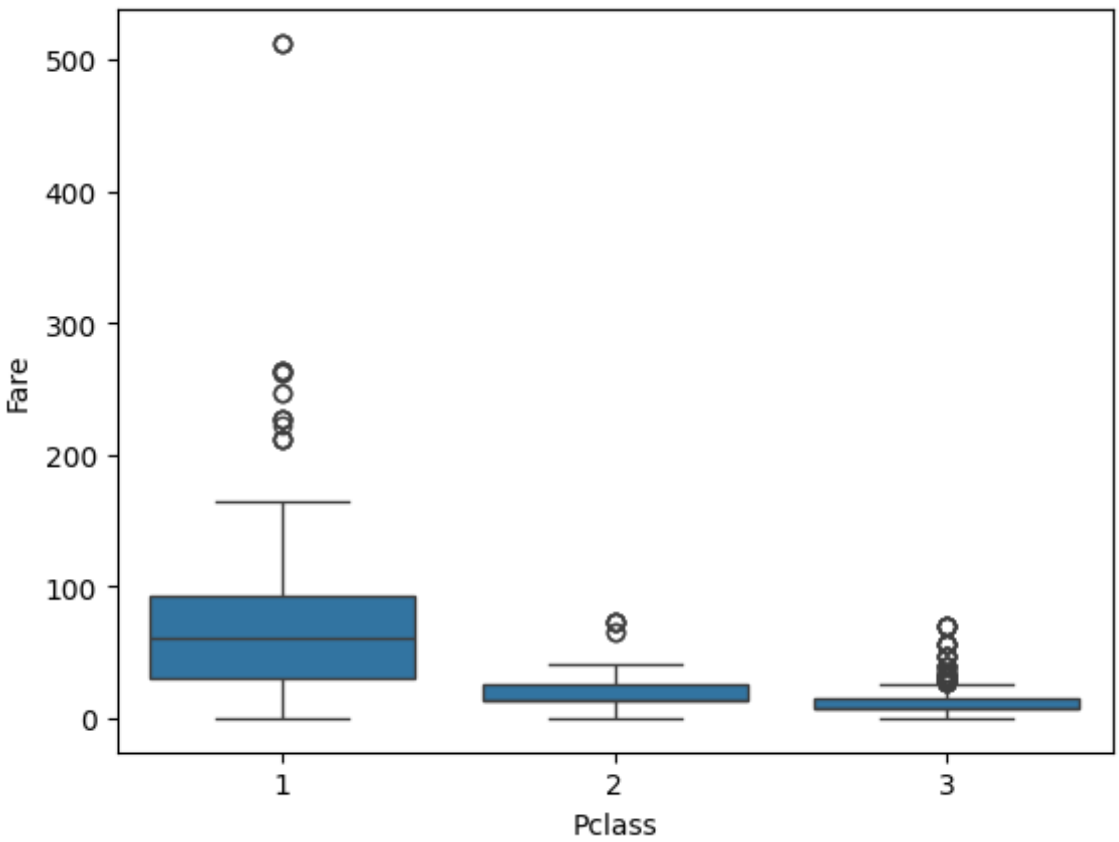
كل لوحة خارج القطر تقارن متغيرين: اسم العمود يحدد المحور الأفقي، واسم الصف يحدد الرأسي. القطر يعرض توزيع كل متغير، واللون يميز نتيجة النجاة. تداخل النقاط يعني أن المتغيرات لا تفصل الناجين فصلا تاما. العمر يتضمن قيما مقدرة، والأسعار ملتوية، وحجم الأسرة متقطع. لا تثبت العلاقات البصرية سببية أو دقة تنبؤ.

كيف تستخدم هذه القراءة؟

استخدم المصفوفة لاستكشاف الأنماط والتداخلات، ثم ارجع إلى المقارنات العددية. لا تضم معرف الراكب أو المتغيرات الثنائية؛ التركيز هنا على العمر وسعر التذكرة وحجم الأسرة.

أسعار التذاكر: اختلاف الفئات

الرسم 7: أسعار التذاكر حسب الدرجة

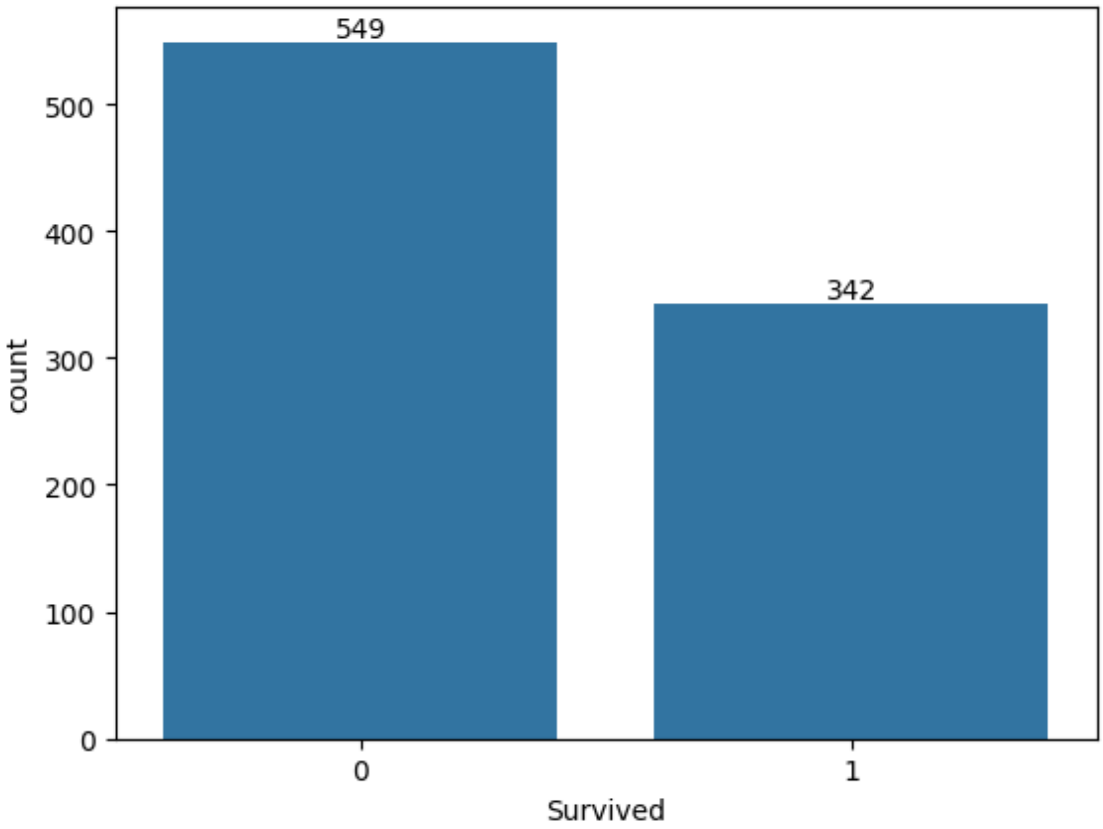


الخط داخل الصندوق هو الوسيط، وحداه الربيعان الأول والثالث. تمتد الشوارب لأبعد قيمة داخل 1.5 IQR من حدود الصندوق، والنقاط الخارجية قيم متطرفة إحصائيا وليست أخطاء مؤكدة. تظهر الأولى أسعارا أعلى وتشتتا أوسع، مع حد أقصى يقارب 512.33. الشوارب تحسب داخل كل درجة، بينما كشف القيم المرتفعة في الكود يستخدم حدا عاما 65.6344 ويجد 116 سجلا يحتفظ بها.

قرار التعامل مع القيم المرتفعة

تظل القيم الـ116 في التحليل؛ لا يثبت الكشف الإحصائي أنها أخطاء. السعر قد يرتبط بحجز مشترك، وليس دخلا شخصيا. المقياس المعروض أصلي وليس لوغاريتميا.

الرسم 8: توزيع نتائج النجاة



Survived = 0 يعني لم ينج، و1 يعني نجا. نجا 342 راكبا، ولم ينج 549؛ نسبة النجاة العامة 38.38%. الأرقام فوق الأعمدة هي أعداد الركاب وليست نسبا. يشكل هذا المعدل مرجعا عاما لقراءة الفروق بين المجموعات، وليس احتمالا ثابتا لكل راكب.

خلاصة الرسومات

ترتبط النجاة في هذه العينة بالجنس والدرجة ووجود أقارب مسجلين. يوضح تحليل العمر أهمية الفصل بين المسجل والمقدر عند تفسير شكل التوزيع. تتداخل نتائج النجاة في مصفوفة المتغيرات، وتبقى أسعار مرتفعة مشروعة محتملة ضمن البيانات.

نطاق البيانات والفحص الأولي

الملف الخام train.csv يضم 891 صفا و12 عمودا. يعرض الكود head وinfo وdescribe، ويحسب الصفوف المتطابقة؛ عددها صفر. تمثل النتائج عينة التدريب المصاحبة للمشروع، لا جميع ركاب السفينة.

1. نسخة عمل وتنظيف النصوص

ينشئ الكود df_clean من df، ويزيل المسافات من أسماء الأعمدة ومن Embarked، ويحول النص الفارغ فيه إلى قيمة مفقودة. المصدر الخام لا يتغير.

2. تعويض العمر وميناء الصعود

العمر ناقص في 177 سجلا (19.87%) ويعوض بوسيط المجموعة المشتركة لـPclass وSex. ميناء الصعود ناقص في سجلين (0.22%)؛ يحسب الكود المنوال ثم يستخدم S صراحة للتعويض. لا يضاف مؤشر دائم للأعمار المقدرة؛ رسم الأعمار المسجلة يستخدم حالة العمر في df الخام.

3. الكابينة والقيم المرتفعة

تظل 687 قيمة Cabin مفقودة (77.10%). سطرا إنشاء Has_Cabin وحذف Cabin معلقان ولا ينفذان. يحسب الكود IQR ويعرض الأسعار الأعلى من 65.6344؛ لا يحذفها ولا ينشئ علامة دائمة لها.

تعريف المتغيرات وحدود الاستنتاج

الحقول الأساسية

Survived: نجا وواحد ينج لم صفر. Pclass: درجة التذكرة من 1 إلى 3. Sex وAge: الجنس والعمر بالسنوات. SibSp: الأشقاء أو الزوج/الزوجة، وParch: الآباء والأبناء على السفينة. Fare: السعر المسجل، وCabin: رقم الكابينة إن سجل، وEmbarked: ميناء الصعود. حقول تعريفية Ticket وName وPassengerId.

الخصائص المشتقة

IsAlone. يساوي واحدا عندما يكون حجم الأسرة المسجل واحدا، ولا يعني غياب الأصدقاء FamilySize = SibSp + Parch + 1 ؛ العدد 83، وكلهم بأعمار مسجلة في هذا الملف. يظل التعليق في الكود مشيرا إلى 16>، بينما التنفيذ الفعلي16 > Age يعتمد على Child يستخدم 16>. يصبح جدول العمل 15 عمودا.

ما الذي تحده البيانات؟

نقص الكابينة لا يعني عدم امتلاك كابينة. التعويض لا يعيد العمر الحقيقي، وقد تتباين الأعمار المفقودة عن المعروفة. قد يعكس Fare حجزا مشتركا. لا توجد فترات ثقة أو اختبارات دلالة أو نماذج مضبوطة، ولا تثبت الرسومات السببية أو دقة التنبؤ. مصدر تنزيل الملف وشروط استخدامه غير موثقين بشكل مستقل في الملفات المتاحة.

التوصيات ودليل التسليم

توصيات الاستخدام

احتفظ بالبيانات الخام، واذكر تعويض العمر ونقص Cabin عند عرض النتائج. اقرأ النسب مع أحجام المجموعات، ولا تحذف الأسعار المرتفعة دون مراجعة سياقها. للتحليل الأعمق، يمكن دراسة تداخل الجنس والدرجة والعمر؛ لم ينفذ ذلك ضمن هذا التسليم. عند تطوير نموذج لاحقا، قسم البيانات أولا وتعلم التعويض من التدريب وحده.

قائمة الملفات

Titanic_cleaning.ipynb: الكود والجداول والرسومات.

train.csv: المصدر الخام. figures: الصور الثماني.

output/pdf: تقريران بالعربية والإنجليزية.

output: نسختان نصيتان قابلتان للتعديل.

requirements.txt وREADME.md: التعليمات والمكتبات.

التشغيل والتحقق

ثبت requirements.txt، وافتح النوتبوك من مجلد المشروع حيث يوجد train.csv، واختر Python ثم Restart Kernel and Run All. في Colab ارفع الملف إلى مجلد العمل. تحقق من 891 راكبا و342 ناجيا وبقاء 687 قيمة مفقودة وظهور ثماني رسومات Cabin. تحفظ الخلية الأخيرة رسم النسب في figures؛ لا يصدر الكود CSV منظفا.