# تقرير تحليل بيانات Titanic



## ملخص تنفيذي

تم تحليل بيانات 891 راكبا، بهدف فهم جودة البيانات وأنماط النجاة. يتناول التقرير تنظيف القيم الناقصة، إنشاء خصائص مرتبطة بالأسرة والعمر، ثم تفسير الرسومات الثمانية التي ينتجها النوتبوك.

## أهم النتائج

نجا 342 راكبا بنسبة 38.38%، ولم ينج 549. نجاة الإناث 74.20% مقابل 18.89% للذكور. نجاة الدرجة الأولى 62.96%، والثانية 47.28%، والثالثة 24.24%.

## حالة التسليم ونطاقه

يتضمن التسليم النوتبوك والبيانات الخام والصور الثماني وتقريري التحليل بالعربية والإنجليزية. يقتصر العمل على تنظيف البيانات والتحليل الوصفي، ولا يتضمن نموذج تنبؤ أو تقديرا سببيا.

## قراءة النتائج

النسب تخص ملف البيانات محل الدراسة. قد تتداخل الدرجة والجنس والعمر وظروف التسجيل؛ لذلك لا تعني الفروق أن متغيرا منفردا سبب النجاة.

# 4.4 الأعمار بعد التعويض

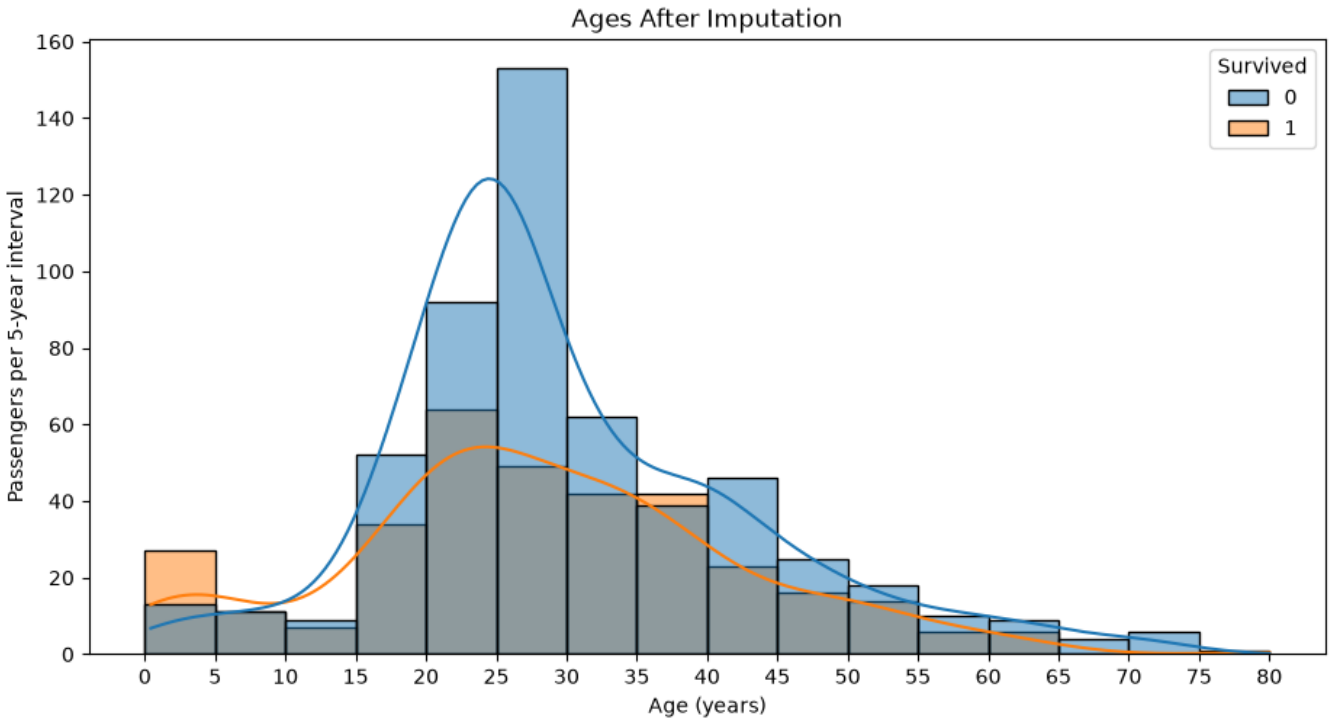


### قراءة الرسم

يعرض الرسم العمر بعد تعويض 177 قيمة مفقودة بوسيط مجموعة الجنس والدرجة. كل عمود يمثل نطاقا عرضه خمس سنوات، واللون يوضح نتيجة النجاة. خطوط KDE تلخص شكل التوزيع، وليست معدلات نجاة.

### النتيجة وحدودها

يتضمن الرسم جميع الركاب البالغ عددهم 891. تظهر أعمار كثيرة في نطاق الشباب والبالغين. قد ينتج عن التعويض قمم عند أعمار الوسيط؛ لذلك يجب مقارنة الشكل برسم الأعمار المسجلة فقط. ارتفاع العدد عند عمر معين لا يثبت ارتفاع فرصة النجاة فيه.



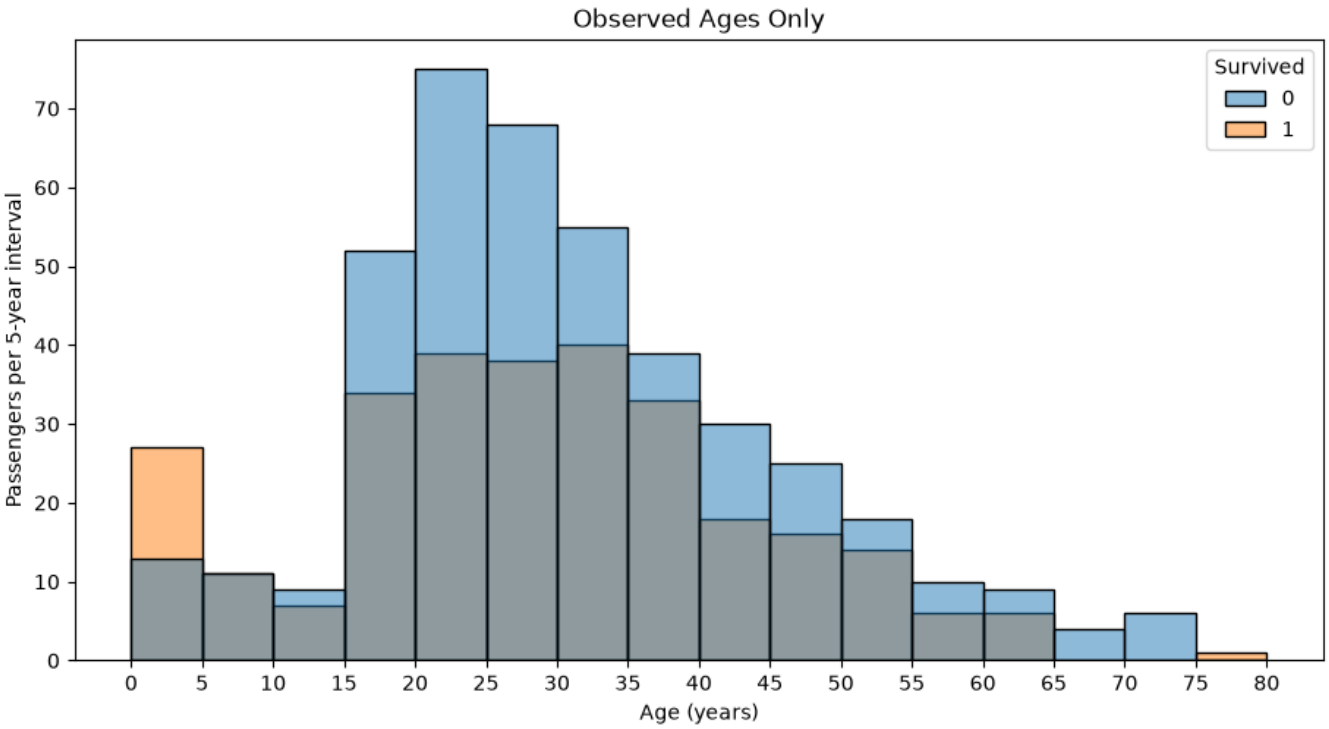
# 4.5 الأعمار المسجلة فقط

### قراءة الرسم

يستخدم الرسم نفس نطاقات العمر السابقة، لكنه يختار الركاب الذين كان العمر معلوما لهم في df الخام باستخدام df[Age].notna(). الاختيار لا يعتمد على قيمة العمر بعد التعويض. يظهر 714 راكبا، ويستبعد 177 عمرا مقدرا من هذا الرسم فقط.

### النتيجة وحدودها

توضح المقارنة حساسية شكل التوزيع لطريقة تعويض القيم الناقصة. لم تحذف الصفوف من البيانات المنظفة؛ الاستبعاد خاص بهذه الصورة. وقد يختلف الركاب ذوو العمر المعروف عن ذوي العمر المفقود، لذلك لا يلغي الرسم تحيز التسجيل ولا يثبت أثر العمر في النجاة.



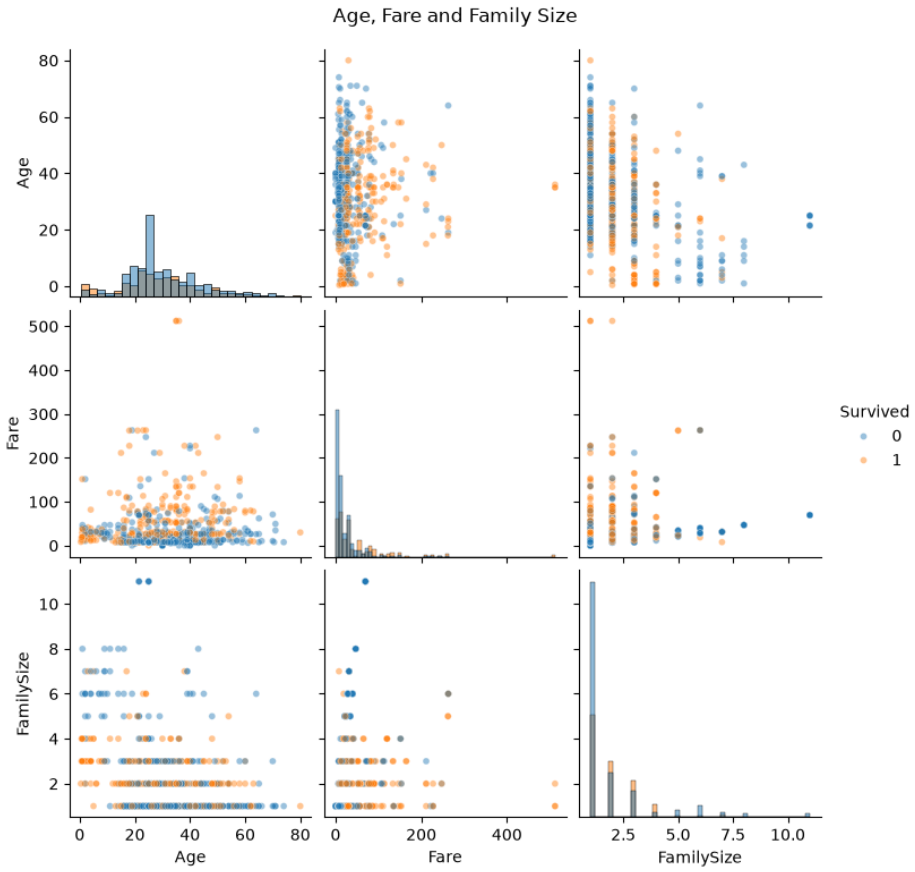
# 4.7 العمر والسعر وحجم الأسرة

## قراءة الرسم

تعرض المصفوفة Age وFare وFamilySize فقط. كل لوحة خارج القطر تربط متغيرين، واسم العمود يحدد المحور الأفقي واسم الصف يحدد الرأسي. القطر يعرض توزيع كل متغير. اللون يميز نتيجة النجاة.

## النتيجة وحدودها

تتداخل نقاط الناجين وغير الناجين، فلا يوجد فصل تام للنتيجة بهذه المتغيرات. العمر يحتوي قيما مقدرة، والأسعار شديدة الالتواء، وحجم الأسرة متقطع. التكدسات الطبيعية أو العلاقات البصرية لا تثبت السببية أو دقة التنبؤ. لا تشمل هذه المصفوفة معرف الراكب أو الخصائص الثنائية.



# 1. نطاق البيانات وفحص الجودة



### بنية الملف

يحتوي train.csv على 891 صفا و12 عمودا. كل صف يمثل راكبا. يعرض الكود head وinfo وdescribe لفهم البنية والأنواع والإحصاءات الوصفية.

### تعريف الحقول

Survived: صفر لم ينج وواحد نجا. Pclass: درجة التذكرة من الأولى إلى الثالثة. Sex وAge: الجنس والعمر بالسنوات. SibSp: الأشقاء أو الزوج/الزوجة على السفينة. Parch: الآباء والأبناء. Fare: سعر التذكرة المسجل. Cabin: الكابينة إن سجلت. Embarked: ميناء الصعود. PassengerId وName وTicket حقول تعريفية.

### القيم الناقصة والتكرارات

العمر مفقود في 177 سجلا (19.87%)، والكابينة في 687 (77.10%)، وميناء الصعود في سجلين (0.22%). لا توجد صفوف متطابقة مكررة في الملف الحالي. يحسب الكود التكرارات ولا يحذف صفوفا.

### حدود المصدر

هذه عينة التدريب المصاحبة للمشروع، وليست سجلا لجميع ركاب السفينة. لا تتوافر ضمن الملفات وثيقة مستقلة توثق مصدر التنزيل وشروط استخدام البيانات. قد يمثل Fare حجزا مشتركا ولا يعبر عن دخل الراكب.

# 2. خطوات التنظيف والخصائص



### إعداد نسخة للعمل

ينشئ الكود df_clean من df، ويزيل المسافات من أسماء الأعمدة ومن Embarked، ويحول النص الفارغ في Embarked إلى قيمة مفقودة. يقرأ train.csv من مجلد العمل نفسه.

### تعويض المفقود

يحسب الكود منوال Embarked، ثم يستخدم S صراحة لملء القيمتين المفقودتين. يملأ 177 عمرا بوسيط المجموعة المشتركة لـPclass وSex. لا توجد علامة منفصلة تحفظ كون العمر مقدرا، ولذلك يجب الرجوع إلى البيانات الخام عند الفصل بين المسجل والمقدر.

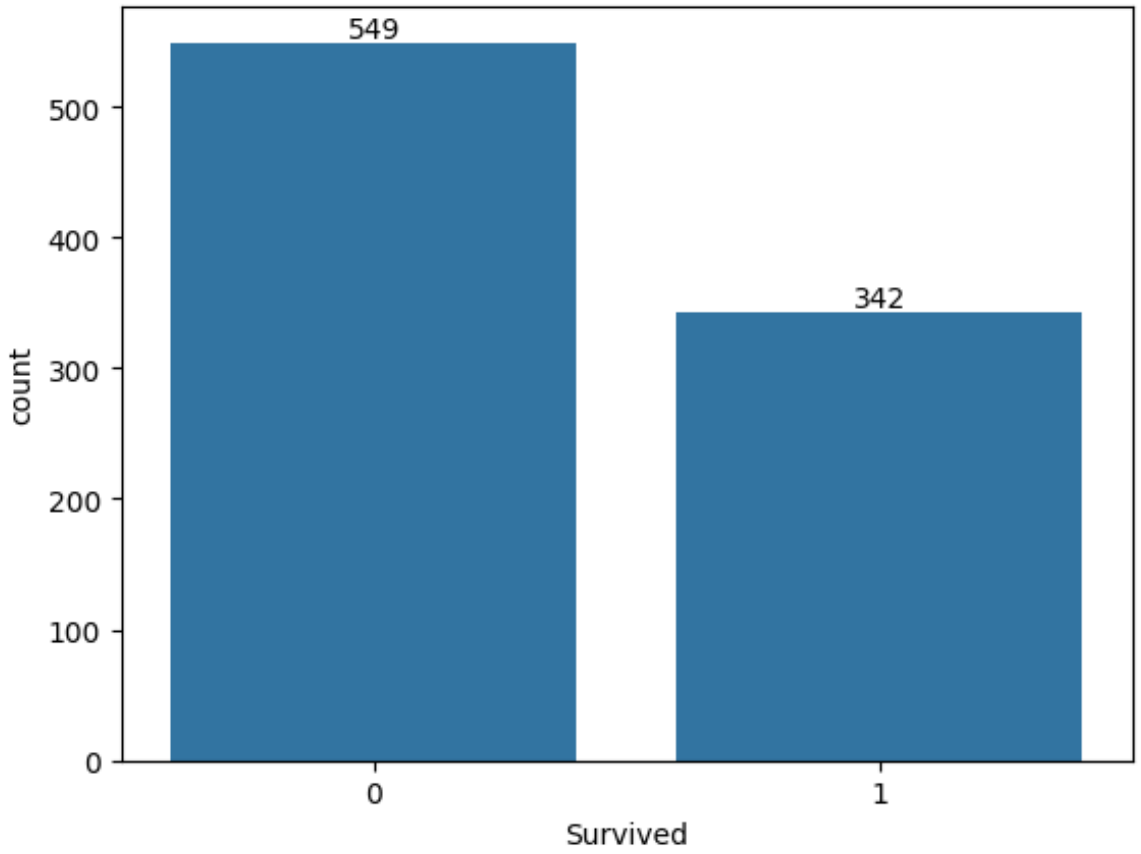
### الكابينة وأسعار التذاكر

يظل Cabin موجودا وبداخله 687 قيمة مفقودة. سطرا إضافة Has_Cabin وحذف Cabin معلقان ولا ينفذان. بالنسبة لـFare، يحسب الكود الحد Q3 + 1.5 × IQR = 65.6344، ويعرض 116 قيمة فوقه دون حذفها أو إضافة علامة لها.

### خصائص الأسرة والطفل

Age يعتمد على Is Child يساوي واحدا عند حجم أسرة مسجل يساوي واحدا. العمود IsAlone .1 + Parch + SibSp = FamilySize < 16 وعدده 83. التعليق فوقه يشير إلى >16، لكن العملية المنفذة فعليا هي أقل من 16. يصبح الجدول أثناء التنفيذ 15 عمودا، ولا يصدر الكود CSV منظفا.

# 3.1 أعداد الناجين وغير الناجين



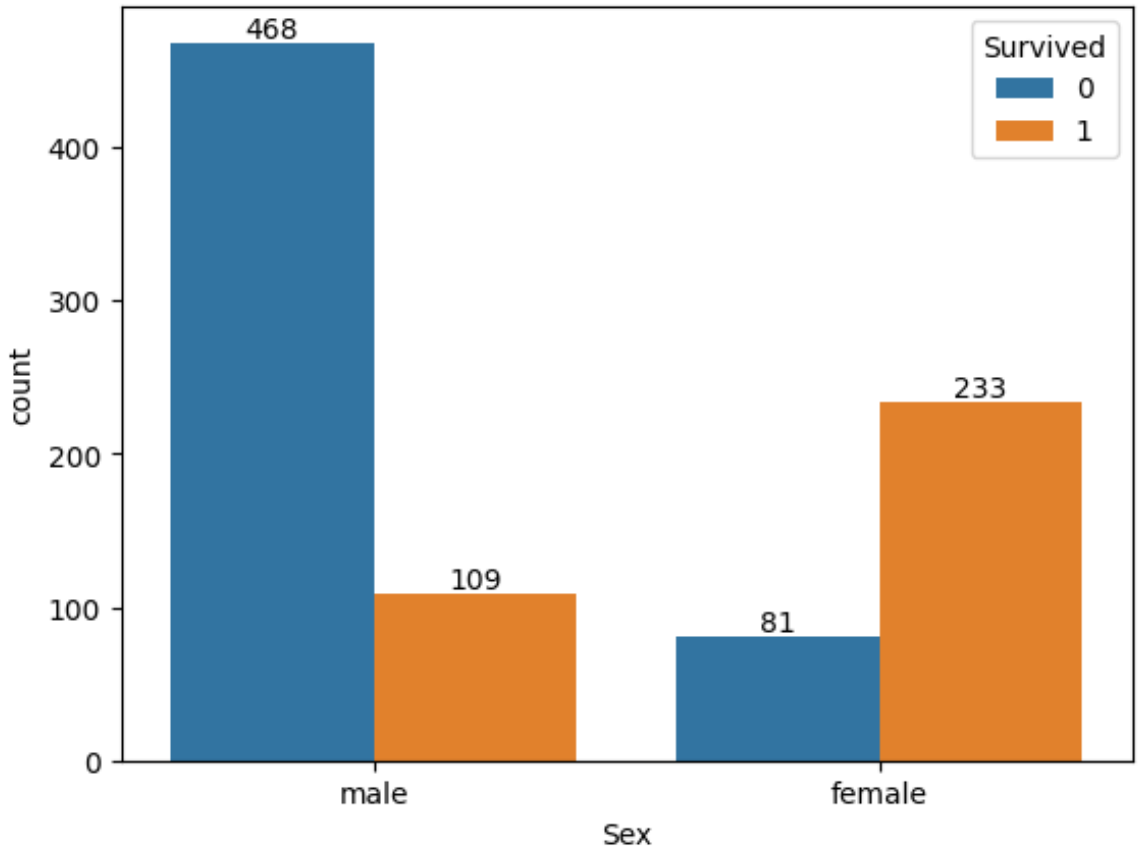

### قراءة الرسم

المحور الأفقي يعرض Survived بقيمتي صفر وواحد، والرأسي عدد الركاب. الرقم فوق كل عمود يحدد العدد الفعلي. صفر يعني لم ينج، وواحد يعني نجا.

### النتيجة والتفسير

549 لم ينجوا مقابل 342 ناجيا. نسبة النجاة العامة 38.38%. النتيجة غير متوازنة عدديا، ويستخدم هذا المعدل كمرجع وصفي للمقارنات التالية؛ لا يمثل احتمالا ثابتا لكل فرد.

# 3.2 الجنس والنجاة



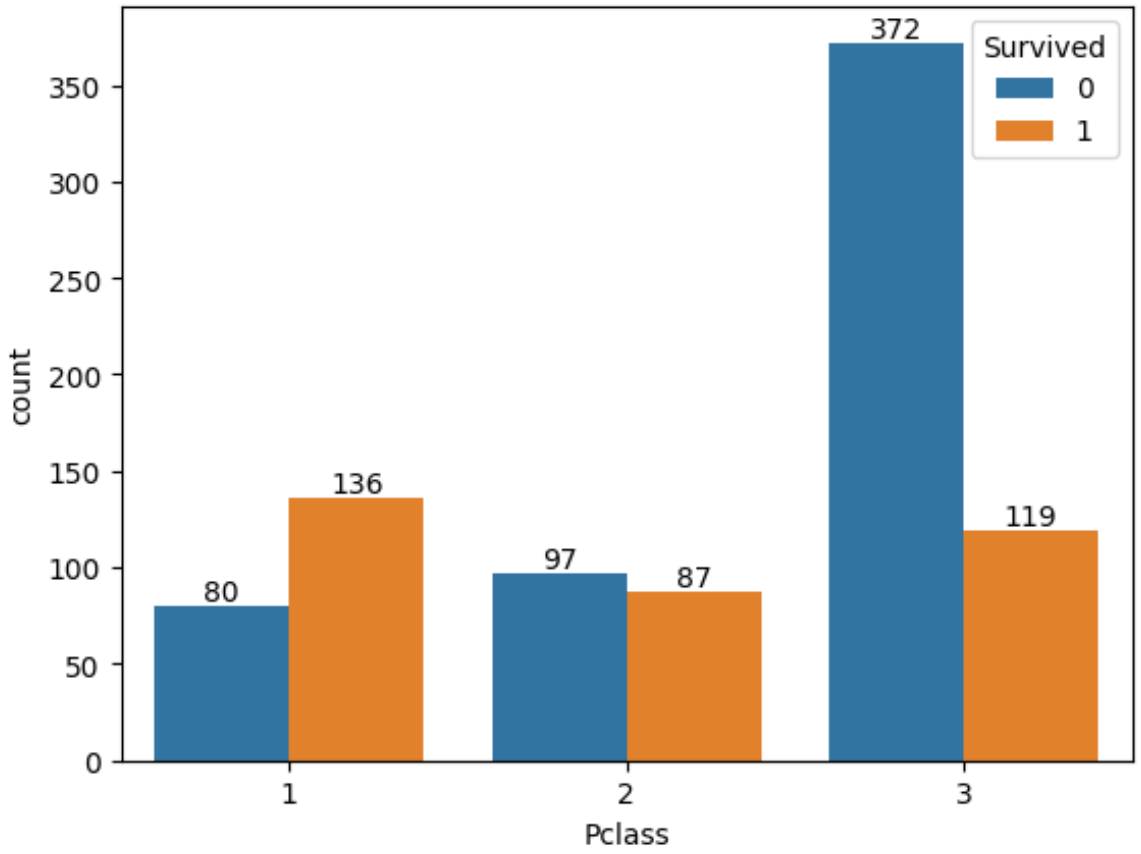

### قراءة الرسم

المحور الأفقي يعرض male وfemale، واللون يوضح النتيجة: الأزرق صفر لم ينج، والبرتقالي واحد نجا. نقارن العمودين داخل كل مجموعة، مع مراعاة اختلاف حجم المجموعتين.

### النتيجة والتفسير

الذكور: 468 لم ينجوا و109 نجوا من أصل 577، بنسبة نجاة 18.89%. الإناث: 81 لم ينجين و233 نجين من أصل 314، بنسبة نجاة 74.20%. فرق المعدلين 55.31 نقطة مئوية. النسب محسوبة لتفسير الأعداد المرسومة؛ لا يعزل الرسم أثر العمر أو الدرجة.

# 3.3 درجة التذكرة والنجاة

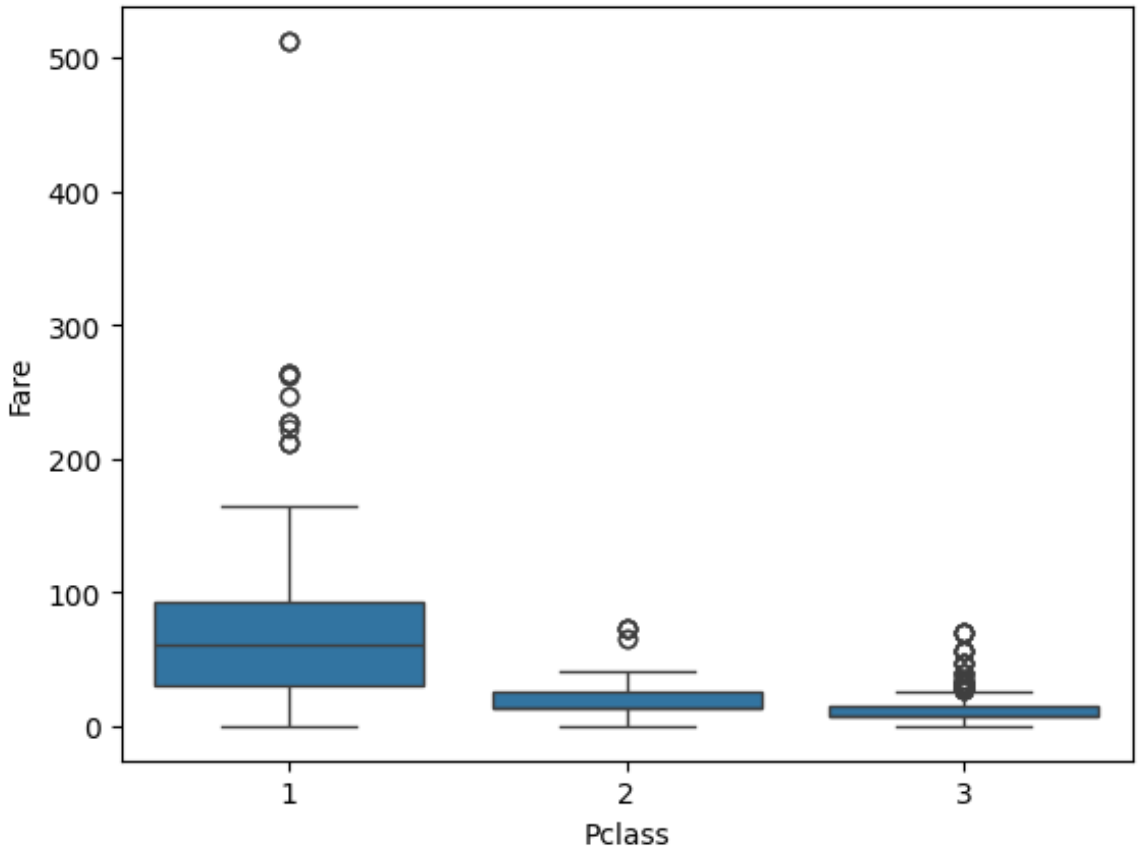



### قراءة الرسم

يعرض المحور الأفقي Pclass من 1 إلى 3، والرأسي عدد الركاب. الأزرق لغير الناجين والبرتقالي للناجين. يجب مقارنة النسب داخل الدرجة لأن أعداد الركاب تختلف بين الدرجات.

### النتيجة والتفسير

الأولى: 136 ناجيا و80 لم ينجوا، بنسبة 62.96%. الثانية: 87 ناجيا و97 لم ينجوا، بنسبة 47.28%. الثالثة: 119 ناجيا و372 لم ينجوا، بنسبة 24.24%. الثالثة تضم العدد الأكبر من الركاب (491). الفروق وصفية وقد تتداخل مع الجنس والعمر وموقع الراكب.



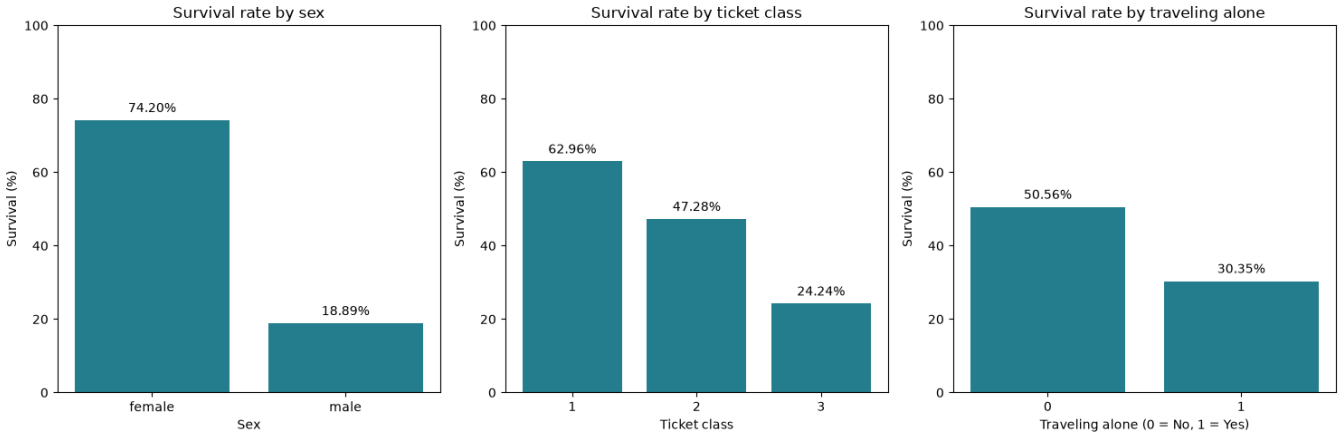

### قراءة الرسم

المحور الأفقي درجة التذكرة والرأسي Fare بالمقياس الأصلي. الخط داخل الصندوق هو الوسيط، وحداه الربيعان الأول والثالث. الشوارب تمتد لأبعد قيمة داخل 1.5 IQR من حدود الصندوق، والنقاط خارجها قيم إحصائية متطرفة.

### النتيجة والتفسير

تظهر الدرجة الأولى أسعارا أعلى وتشتتا أكبر، مع قيمة قصوى تقارب 512.33. النقاط البعيدة ليست أخطاء مؤكدة. شوارب الرسم تحسب داخل كل درجة؛ أما قائمة القيم المرتفعة في الكود فتستخدم حدا عاما قدره 65.6344 للملف كله. لا يحذف الكود أسعارا مرتفعة، ولا يستخدم الرسم مقياسا لوغاريتميا.

# 3.8 مقارنة نسب النجاة




## قراءة الرسم

تعرض اللوحات معدل النجاة حسب الجنس، ثم درجة التذكرة، ثم السفر منفردا. المحور الرأسي من صفر إلى 100%، والنسبة مكتوبة فوق كل عمود. يحسب الكود متوسط Survived داخل كل مجموعة ويضربه في 100، لأن المتغير يأخذ صفرا أو واحدا.

## النتيجة والتفسير

نجاة الإناث 74.20% والذكور 18.89%. حسب الدرجة: الأولى 62.96%، الثانية 47.28%، والثالثة 24.24%. IsAlone = 0 لمن معهم أقارب مسجلون ونسبة النجاة 50.56%، و1 لمن يسافرون منفردين ونسبتهم 30.35%. اختلاف النسب لا يثبت علاقة سببية.

## أحجام المجموعات وحدود المقارنة

الإناث 314 والذكور 577؛ درجات التذكرة تضم 216 و184 و491 على الترتيب. مع أقارب مسجلين 354، ومنفردون 537. النسب تقارن داخل المجموعات، ولا توجد فترات ثقة أو اختبارات دلالة. السفر منفردا يتعلق بالأقارب في البيانات، وليس غياب الأصدقاء.

# 4. الخلاصة والقيود والتوصيات



### خلاصة النتائج

تختلف نسب النجاة حسب الجنس والدرجة في هذه العينة. يحسب الكود أيضا نجاة المسافرين وحدهم (30.35%) ومن لديهم أقارب مسجلون (50.56%)، ويعرض رسم النسب هذه المقارنة مع الجنس ودرجة التذكرة. IsAlone يصف الأقارب في SibSp وParch، وليس الأصدقاء أو جميع المعارف.

### قيود يجب مراعاتها

يبقى Cabin ناقصا بكثرة، ولا توجد خصائص لتوافره. العمر المقدر لا يتم تمييزه بعلامة منفصلة، ويؤثر في شكل توزيع العمر. لا توجد اختبارات دلالة أو فترات ثقة أو نماذج مضبوطة. لا يمثل ملف التدريب كل ركاب السفينة، ولا تثبت الرسومات أسباب النجاة.

### توصيات استخدام البيانات

احتفظ بالمصدر الخام، ووثق تعويض العمر ونقص Cabin عند مشاركة النتائج. استخدم الأعداد والنسب معا، ولا تحذف الأسعار المرتفعة دون مراجعة المصدر. عند تطوير نموذج لاحقا، قسم البيانات أولا وتعلم التعويض من التدريب وحده. هذه توصيات مستقبلية وليست خطوات إضافية منفذة في الكود.

# 5. الملفات وإعادة التشغيل



### قائمة التسليم

Titanic_cleaning.ipynb: الكود والتحليل ومخرجاته.

train.csv: البيانات الخام.

figures: ثماني صور مستخرجة من مخرجات النوتبوك.

output/pdf: تقريران بالعربية والإنجليزية.

output: نسختان نصيتان من التقريرين.

requirements.txt وREADME.md: التعليمات والمكتبات.

### التشغيل

ثبت المكتبات في requirements.txt، وافتح النوتبوك من مجلد المشروع حيث يوجد train.csv، واختر Python kernel ثم Restart إلى مجلد العمل. ينتج الكود الرسومات والجداول داخل النوتبوك، ويحفظ رسم النسب train.csv ارفع Colab في .Kernel and Run All في figures، بينما لا يصدر CSV تلقائيا.

### التحقق والتوثيق

مرجع التحقق هو تنفيذ النوتبوك وقراءة بياناته: 891 راكبا و342 ناجيا، وبقاء 687 قيمة Cabin مفقودة، وإنتاج ثماني رسومات. تاريخ التقرير 20 أكتوبر 2026. الأرقام الوصفية في الشرح محسوبة من البيانات لتفسير الرسومات، ولا تعني وجود رسوم أو اختبارات إضافية.